

智闻辨真：基于 RAG 与大语言模型的新闻 可信度评估系统 综合设计报告

完成人：龙浩

学号：2023013753

班级：物联网 23A1

目录

第 1 章 绪论	1
1.1 研究背景	1
1.2 研究目的与意义	2
1.3 国内外研究现状	3
1.4 当前存在的问题	5
1.5 本系统的主要研究内容	6
1.6 本系统的创新点	7
1.7 系统开发技术路线	8
第 2 章 系统需求分析	9
2.1 系统需求概述	9
2.2 系统功能需求分析	11
2.3 系统业务流程分析	15
2.4 系统非功能需求分析	17
2.5 本章小结	20
第 3 章 系统开发环境与关键技术	20
3.1 技术选型目标与总体说明	20
3.2 系统开发与运行环境	21
3.3 Web 应用开发技术	22
3.4 关系数据存储与结构版本管理	23
3.5 文本 Embedding 与向量语义检索	24
3.6 RAG 与大语言模型证据分析技术	27
3.7 业务支撑与可复现性技术	29
3.8 本章小结	32
第 4 章 系统总体设计	33
4.1 系统设计目标与原则	33
4.2 系统总体架构设计	35
4.3 系统功能模块设计	38
4.4 新闻可信度评估流程设计	41

4.5 数据库设计	46
4.6 接口与权限体系设计	50
4.7 系统安全性与可靠性设计	52
4.8 用户界面与交互设计	54
4.9 本章小结	56
第 5 章 系统详细设计与实现	57
5.1 系统实现概述	57
5.2 用户认证与权限控制实现	59
5.3 新闻输入与网页内容提取实现	60
5.4 新闻知识库与本地语义检索实现	63
5.5 多源候选证据获取与组织实现	64
5.6 大语言模型分析与证据仲裁实现	67
5.7 可信度评分与风险分类实现	70
5.8 检测结果持久化与查询实现	72
5.9 知识库跨存储一致性与恢复实现	73
5.10 检测报告生成与文件管理实现	75
5.11 前端主要功能实现	76
5.12 异常处理、系统日志与运行保障	81
5.13 本章小结	84
参考文献	85

第 1 章 绪论

1.1 研究背景

网络新闻平台、社交媒体和短视频平台降低了新闻生产与传播门槛，也使信息来源更加复杂、传播速度更快。普通用户在有限时间内往往难以核验新闻来源、事实依据和传播背景，尤其在公共安全、医疗健康、金融投资和突发事件等场景中，错误信息可能放大社会恐慌并影响公众判断。已有研究指出，虚假新闻检测不能只关注文本表面特征，还需要结合来源、上下文和外部证据进行综合判断^[1]。

传统新闻真伪鉴别方法主要包括人工审核、规则匹配、机器学习分类和深度学习检测。人工审核具有较强的专业性，但在海量信息和突发舆情场景下存在响应滞后、成本较高的问题；规则匹配和分类模型可以提升处理效率，但通常更偏向输出“真实”或“虚假”等分类结果，在证据追溯、判断理由展示和用户可理解性方面仍然不足。对于面向普通用户的新闻可信度辅助评估工具而言，系统不仅需要给出风险判断，还需要说明判断依据。

大语言模型具备较强的语义理解、信息概括和推理解释能力，能够辅助分析新闻文本中的风险表达、事实矛盾和语义倾向。然而，大语言模型并不等同于事实核查系统。自然语言生成模型可能产生与输入内容或外部事实不一致的幻觉信息^[3]，在缺少外部证据约束时，其判断结论可能存在事实依据不足、输出不稳定和难以追溯的问题。因此，新闻可信度评估不能只依赖大语言模型直接判断，而需要引入 RAG 证据检索、规则评分和可解释输出机制。

检索增强生成技术（Retrieval-Augmented Generation, RAG）通过在生成前检索外部知识资料，为大语言模型提供可追溯的上下文证据。Lewis 等人提出的 RAG 方法将预训练生成模型与外部非参数化知识检索机制结合，使生成结果能够基于检索文档展开^[2]。但是，语义相似度只能反映文本内容的接近程度，不能直接证明候选材料真实、可靠或与待评估新闻具有支持、反驳关系。因此，新闻可信度评估还需要对候选证据的相关性、质量和立场进行进一步分析。

基于上述背景，本文设计“智闻辨真：基于 RAG 与大语言模型的新闻可信度评估系统”。系统定位为新闻可信度辅助评估工具和风险提示工具，围绕“新闻输入—本地检索—按需联网补充—候选证据组织—大语言模型仲裁—证据质量校验—分支式综合评分—结果解释”的业务链路开展设计与实现。

1.2 研究目的与意义

1.2.1 研究目的

本研究旨在设计并实现一个基于检索增强生成技术与大语言模型的新闻可信度评估系统，通过多源证据获取、证据语义仲裁、分支式可信度评分以及结果追溯等机制，增强新闻可信度评估的证据支撑能力、可解释性与系统鲁棒性。具体研究目的如下。

其一，构建本地知识检索与按需联网补充相结合的多源证据获取机制。系统优先从 Chroma 向量数据库中召回相关证据，当本地证据不足时，在用户授权和系统配置允许的条件下补充网络信息。检索相似度仅用于候选召回和证据充足性判断，不直接代表证据可信度。

其二，构建证据约束下的大语言模型分析与仲裁机制。系统对本地证据和网络证据进行统一格式化、去重和标识，由 DeepSeek 对证据的相关性、质量和立场进行判断。服务端对模型输出进行结构与范围校验，避免无效证据直接参与评分。

其三，设计基于模型状态和证据状态的分支式可信度评分机制。系统综合大语言模型可信度分、证据质量分和确定性规则分进行评估，并根据模型服务和有效证据的可用情况选择评分分支。模型服务异常时，系统自动采用规则评分并标记降级状态。

其四，实现评估结果的可解释与可追溯。系统展示可信度评分、风险等级、判断理由、风险点及证据使用情况，并保存候选证据、仲裁结果和异常信息，为用户理解结果、管理员复核及后续方法优化提供依据。

1.2.2 研究意义

从现实意义来看，本系统面向普通用户在网络新闻阅读中的可信度判断需求，提供一种基于证据和规则的风险提示方式。当用户面对来源不明、标题夸张或内容难以核验的新闻时，系统能够给出初步风险判断和可查看的证据材料，帮助用户提升信息辨别意识。系统不替代专业事实核查和人工审核，而是作为新闻阅读过程中的辅助评估工具。

从技术意义来看，本系统探索了 RAG、多源信息检索、大语言模型证据仲裁、确定性规则评分和 Web 应用系统的协同方式。系统使用 Chroma 完成本地候选召

回，在本地证据不足时按需引入联网信息，并通过统一候选标识和来源中立排序降低证据来源及输入位置对模型判断的影响。大语言模型负责语义分析和逐条证据仲裁，服务端负责输出契约检查、证据质量重算和评分分支选择，从而限制生成式模型未经校验的结果直接改变最终业务状态。

从课程设计意义来看，本系统综合涉及软件工程、数据库设计、Web 后端开发、前端页面设计、人工智能应用开发、Prompt 工程和数据可视化等内容。相比普通信息管理系统，本系统更能体现 AI 应用系统中数据管理、证据检索、模型调用、结果解释和工程实现之间的协同关系。

1.3 国内外研究现状

1.3.1 虚假新闻检测与事实核查研究现状

虚假新闻检测是自然语言处理、数据挖掘和内容安全领域的重要研究方向。早期方法多依赖人工特征、情感倾向、新闻来源、传播路径和用户行为等信息，再结合机器学习模型完成分类。随着深度学习和预训练语言模型的发展，研究逐渐从单一文本分类扩展到多源信息融合、证据检索和可解释事实核查。Shu 等人指出，社交媒体虚假新闻检测不仅依赖新闻内容，还需要考虑用户社交行为、传播关系和上下文因素[1]；Yang 等人对事实核查类虚假新闻检测进行了综述，强调证据检索、证据推理和解释输出的重要性[4]。

上述研究表明，虚假新闻检测不能停留在简单分类层面。对本系统而言，用户更需要看到“为什么存在风险”和“依据来自何处”，因此系统设计应将相似证据召回、来源信息和判断理由作为核心输出内容。

1.3.2 大语言模型在新闻可信度评估中的应用

大语言模型在文本理解、摘要生成、观点分析和推理解释方面具有较强能力，能够用于新闻主题识别、风险点提取和判断理由生成。Quelle 和 Bovet 研究了大语言模型用于事实核查的可能性，认为模型在获得上下文信息时具有一定辅助价值，但其表现会受到声明类型、查询语言和证据质量等因素影响[5]。Ji 等人的研究进一步指出，自然语言生成模型可能出现幻觉问题[3]。

因此，大语言模型适合作为新闻可信度评估中的语义分析组件，而不宜作为唯一判断依据。本系统采用 Prompt 模板约束模型输出格式，并通过检索证据和规则评分对模型判断进行补充，避免将模型生成结果直接等同于事实核查结论。

1.3.3 RAG 技术在事实验证中的应用

RAG 技术的核心思想是在生成回答前先检索外部知识材料，再将检索结果与输入内容共同提供给生成模型。Lewis 等人提出的 RAG 模型将生成模型与密集向量检索器结合，为开放域问答等知识密集型任务提供了外部知识支撑^[2]。在自动事实核查领域，Ullrich 等人将事实核查任务重新表述为 RAG 流程，通过检索器和证据标签生成模块完成证据获取与判断^[7]；Yue 等人提出的 RAFTS 方法强调在事实验证中综合支持证据与反驳证据^[8]。

这些研究为本系统提供了直接启示：新闻可信度评估应先召回可追溯的外部证据，再让大语言模型在证据约束下分析新闻内容。与此同时，RAG 效果依赖检索质量，系统需要记录证据标题、摘要、来源、相似度和可信状态，以便用户理解证据来源。

1.3.4 国内中文虚假新闻检测研究现状

中文虚假新闻检测还面临跨来源、跨平台和表达方式差异等问题。Li 等人构建的 MCFEND 数据集指出，单一来源训练方法在多来源测试场景中泛化能力会明显下降^[6]。这说明真实应用中的新闻可信度评估不能只依赖固定数据来源或单一文本模式，而需要在知识库维护、来源信息记录和风险规则设计上具备一定扩展能力。

对本系统而言，中文新闻场景下的跨来源差异要求系统在知识库中保留来源、类别、摘要和可信状态等字段，并在规则评分阶段考虑来源可靠性、敏感类别和证据冲突等因素，从而为后续扩充多来源知识材料提供基础。

研究现状小结：已有研究为新闻可信度评估提供了文本分类、传播特征分析、事实核查、大语言模型推理和 RAG 证据检索等方法，但仍存在若干不足。传统虚假新闻检测较为重视分类结果，对证据来源和判断过程的展示不足；大语言模型具备较强的语义分析能力，但可能产生幻觉、遗漏证据或输出结构不稳定；RAG 能够补充外部知识，但语义相似度并不能直接代表证据真实性，检索候选仍需要进行相关性、质量和立场判断。此外，当证据不足、证据冲突或外部模型不可用时，固定评分方式可能产生缺乏依据的结果。

因此，本系统采用本地知识检索与按需联网补充相结合的候选获取方式，通过大语言模型完成逐条证据仲裁，并由服务端执行证据契约校验和质量重算；最

终根据模型和有效证据的可用状态采用分支式评分与异常降级策略,形成面向普通用户的可解释新闻可信度辅助评估流程。

1.4 当前存在的问题

第一,人工核查效率难以满足高频新闻传播场景。网络新闻数量大、传播速度快,仅依靠人工审核难以及时处理大量用户提交内容。针对该问题,本系统设计自动化检测流程,通过输入校验、文本预处理、向量检索、模型分析和规则评分完成初步风险评估,提升单条新闻处理效率。

第二,传统检测结果解释性不足。部分检测工具只输出“真实”或“虚假”等分类结论,缺少相似证据、判断理由和风险点说明。针对该问题,本系统在检测结果中展示可信度评分、风险等级、判断理由、风险点、检索证据、相似新闻和辟谣建议,使普通用户能够理解系统判断依据。

第三,大语言模型输出存在不稳定性和不可直接信任的问题。大语言模型可能遗漏候选证据、引用不存在的证据标识、给出超出范围的分值,或者在缺少充分依据时生成确定性结论。针对该问题,本系统为每条候选证据设置稳定标识,要求模型将所有候选完整划分为有效证据和排除证据,并输出相关性、质量、立场及理由。服务端继续执行字段、分值、枚举值和候选完整性校验;首次仲裁不符合要求时进行一次聚焦重试,仍不符合要求的候选不参与综合评分。

第四,证据质量和来源可信度会影响判断结果。当检索证据不足、证据相互冲突或来源可靠性较低时,模型分析结果可能受到影响。已有研究也指出,冲突证据会降低检索增强事实核查的可靠性,引入来源可信度有助于提升处理稳健性^[9]。针对该问题,本系统在规则评分中考虑来源缺失、夸张表达、敏感类别和证据冲突等因素,并在结果中提示相关证据不足等情况。

第五,系统持续管理能力不足会限制应用效果。新闻可信度评估不仅依赖单次模型调用,还依赖知识库持续维护、检测记录追踪、高风险新闻管理和运行数据分析。针对该问题,本系统设计管理员后台,支持知识库、Prompt 模板、检测记录、高风险新闻、报告、系统日志和 ECharts 可视化等管理功能,为系统持续运行提供工程支撑。

1.5 本系统的主要研究内容

1.5.1 新闻证据库构建与语义检索机制

系统围绕新闻可信度评估任务构建本地新闻知识库，保存新闻标题、正文、摘要、来源、类别、可信状态和辟谣说明等信息。知识文本经过向量化后写入 Chroma，用户提交新闻后，系统根据标题和正文召回语义相关候选，并通过知识条目标识回查 MySQL 中的当前业务数据，过滤已经失效或不存在的向量记录。

当本地知识库没有召回候选，或者召回结果的数量和相似度不能满足设定条件时，系统在用户允许的情况下调用联网搜索补充近期证据。本地证据和网络证据经过统一格式化、URL 规范化、重复项合并和稳定候选标识生成后形成候选证据集合。检索相似度用于候选发现、证据不足判定和展示，不直接进入最终可信度评分。

1.5.2 证据约束的大语言模型可信度分析机制

系统将待评估新闻、统一候选证据和输出格式要求组织成 RAG Prompt，并调用 DeepSeek 大语言模型生成结构化分析结果。模型除输出新闻可信度分量、判断理由、风险点、关键词和建议外，还需要对每条候选证据给出相关性、质量、立场和取舍理由。

系统将候选证据划分为有效证据集合和排除证据集合。有效证据记录候选标识、相关性分、质量分、支持或反驳立场及判断理由；排除证据记录候选标识和排除原因。服务端要求两个集合共同构成全部候选标识的完整且不重复划分，并检查字段类型、分值范围和枚举值。仲裁结果不符合契约时，系统进行一次聚焦重试；重试后仍不满足要求的候选不参与后续证据评分。

1.5.3 证据质量计算与分支式综合评分机制

系统设置大语言模型可信度分 (S_L)、确定性规则分 (S_R) 和证据质量分 (S_E)，三项分值均规范到 0~100 范围。证据质量分由证据覆盖度 (C) 和证据一致性 (K) 组成，其计算公式如式 (1-1) 所示：

$$[S_E = 0.6C + 0.4K \quad (1-1)]$$

式中，(C)表示有效证据对待评估新闻核心内容的覆盖程度，(K)表示有效证据之间以及证据与新闻判断之间的一致程度。为减少模型直接生成总分造成的计算偏差，服务端根据模型返回的覆盖度和一致性重新计算证据质量分。

最终可信度分数根据模型与有效证据的可用状态分为三种情况：

- ① 模型失败： $S=S_R$
- ② 模型可用但无有效证据： $S=0.6S_L+0.4S_R$
- ③ 存在有效证据： $S=0.5S_L+0.3S_E+0.2S_R$

当模型服务不可用时，系统不使用未经仲裁的候选证据，也不伪造证据质量分，而是退化为确定性规则评分，并在结果中标记模型服务异常。当模型可用但不存在通过仲裁的有效证据时，评分由模型可信度分和规则分组成；当存在有效证据时，模型可信度分、证据质量分和规则分共同参与计算。

最终分数(S)按照统一阈值映射为风险等级： $(S \geq 80)$ 为可信新闻， $(60 \leq S < 80)$ 为存疑信息， $(40 \leq S < 60)$ 为疑似谣言， $(S < 40)$ 为高风险谣言。上述分值属于辅助风险评估结果，不替代专业事实核查结论。

1.5.4 可解释结果输出与系统管理支撑

系统面向普通用户提供可信度评分、风险等级、判断理由、风险点、关键词、有效证据、排除证据、相似新闻及辟谣建议等分析结果，并支持生成 PDF 检测报告，以直观呈现新闻可信度评估结论及其依据。

为保证评估过程可追溯，系统同步保存各评分分量、候选证据、证据仲裁结果、证据质量状态、异常摘要及分析契约版本等信息，使用户和管理员能够对检测依据、评分过程及异常情况进行查询与复核。

管理员端提供知识库、Prompt 模板、检测记录、高风险新闻、用户、报告、系统日志和数据可视化等管理功能，并支持知识向量同步与索引重建，为证据数据维护、检测结果复核、运行状态监控及系统持续维护提供支撑。

1.6 本系统的创新点

第一，设计本地检索与按需联网补充相结合的多源候选证据获取机制。系统优先从可维护的本地新闻知识库中检索相关内容，当本地候选数量不足或最高相似度低于设定阈值时，按条件调用联网检索补充时效性信息。对于本地证据和网络证据，系统采用统一的数据结构、稳定的候选标识和来源中立的排序方式进行组织，以减少证据来源顺序对大语言模型分析结果的影响，提高多源证据处理的一致性。

第二，设计面向候选证据的结构化仲裁与契约校验机制。系统要求大语言模型逐条输出候选证据的相关性、质量、立场及判断理由，并将所有候选完整划分为有效证据和排除证据。服务端进一步对候选标识、字段类型、分值范围、证据划分完整性及重复情况进行校验，使未经仲裁、字段缺失或不满足输出契约的候选无法直接参与综合评分，从而降低模型输出不规范对评估结果的影响。

第三，设计基于模型状态与证据可用性的分支式评分和异常降级机制。系统不将检索相似度直接作为新闻可信度评分，而是根据有效证据的覆盖程度、一致性和质量计算证据质量分量，并结合模型服务状态与有效证据数量选择相应的评分分支。当大语言模型调用失败、输出解析异常或有效证据不足时，系统切换至确定性规则评分，同时记录并展示异常状态，避免无效评分分量、未验证证据或虚构内容进入最终评估结果，提高系统在异常情况下的稳定性与结果可信度。

1.7 系统开发技术路线

本系统采用前后端分离架构。前端使用 Vue3、Element Plus 和 ECharts 实现用户端页面、管理员后台页面和数据可视化页面；后端使用 Python 和 FastAPI 实现业务接口、用户认证、新闻检测、知识库管理、Prompt 管理和报告生成；数据库使用 MySQL 存储用户信息、知识库数据、检测记录、报告信息和系统日志；向量数据库使用 Chroma 存储新闻知识库向量；大语言模型分析模块通过 DeepSeek API 实现。

系统整体技术路线如下：用户输入新闻标题和正文后，系统首先进行输入校验、文本预处理和关键词提取；随后将输入内容转换为向量，并在 Chroma 向量数据库中检索相似新闻和相关证据；系统将检索证据与用户输入内容拼接成 RAG Prompt，并调用 DeepSeek 大语言模型进行可信度分析；之后系统执行规则评分，对来源缺失、夸张表达、敏感类别和证据冲突等风险因素进行辅助判断；最后系统根据综合评分公式计算可信度分数，生成风险等级、判断理由、风险点、证据材料、辟谣建议和 PDF 检测报告。开发路线图如图 1-1 所示。




图 1-1 系统总体技术路线

第 2 章 系统需求分析

2.1 系统需求概述

本系统面向网络新闻阅读与管理场景,提供基于检索证据和大语言模型分析的新闻可信度辅助评估能力。需求分析关注系统应向不同角色提供何种服务、输入与输出需要满足哪些约束,以及外部服务或数据同步异常时系统应如何表现,不在本章展开具体框架、接口路径、算法公式和数据库字段设计。

系统核心业务由新闻输入、候选证据获取、证据仲裁、分支式评分、结果解释、记录与报告管理以及管理员复核构成。各项需求使用 FR-U、FR-A、FR-S 和 NFR 编号,作为第 4 章总体设计、第 5 章系统实现和第 6 章测试验收的追踪依据。

2.1.1 系统定位与业务边界

“智闻辨真”定位为新闻可信度辅助评估与风险提示工具。系统根据用户提交的新闻内容检索相关材料,对候选证据进行取舍并形成评分、风险等级和解释信息,帮助用户识别需要进一步核验的内容。系统输出不构成具有法律效力的真假认定,也不替代专业事实核查、权威机构结论或人工审核。

系统业务范围包括手工输入与 URL 内容预览、本地知识检索与按需联网补充、候选证据标准化、模型证据仲裁、服务端契约校验、分支式评分、结果持久化、个人历史与报告，以及知识、Prompt、高风险记录、用户、检测、报告、统计和日志管理。网页内容须经用户确认或修订后才能进入正式评估，自动提取结果不直接作为检测事实。

证据不足、证据冲突或外部能力不可用时，系统不得输出超出当前依据的确定性结论。检索相似度仅用于候选召回、判断是否需要联网补充和结果展示，不直接等同于证据质量或新闻可信度。系统应公开证据不足、仲裁失败和降级状态，使用户能够理解结果的能力边界。

2.1.2 系统角色分析

系统角色分为游客、注册用户和管理员。三类角色共享新闻可信度辅助评估这一业务目标，但在记录归属、个人数据访问和管理权限方面具有不同边界；角色与主要功能需求在表 2-1 中统一列示。

游客可以浏览公开信息、使用 URL 预览并提交一次性检测。游客检测记录不绑定用户账号，结果仅用于承接当次检测，不开放个人历史、持久化详情和报告能力。

注册用户继承游客的基础功能，并可查看本人历史与检测详情、基于旧记录重新发起评估，以及根据本人已保存的检测结果生成和下载报告。个人数据访问必须校验记录归属，重新评估应生成新记录而不是覆盖原记录。

管理员在注册用户能力基础上承担系统治理职责，可以维护知识库和 Prompt 模板，查看向量同步状态并执行恢复操作，复核高风险新闻及其公开状态，管理用户、检测记录和报告，并查看统计与系统日志。系统自动生成的风险等级仅作为管理员复核线索，不能自动等同于人工复核结论。

系统总体用例关系如图 2-1 所示。注册用户继承游客的基础业务能力，管理员进一步取得治理与审计能力。




图 2-1 系统总体用例图

2.2 系统功能需求分析

系统功能需求分为用户功能需求、管理员功能需求和智能评估支撑需求。表 2-1 以稳定编号给出角色或支撑主体、主要输入、主要输出以及异常或边界要求；同一编号在后续设计、实现和测试中应保持语义一致。

表 2-1 系统角色与主要功能需求表

编号	角色/主体	功能需求	主要输入	主要输出	异常或边界要求
FR-U01	游客/注册用户	新闻文本输入	标题、正文、来源、发布时间	规范化待评估内容	标题或正文为空时拒绝提交
FR-U02	游客/注册用户	URL 内容预览	HTTP/HTTPS 新闻 URL	可确认、可修订的内容预览	提取失败保留原链接并允许重试或改为手工输入
FR-U03	游客/注册用户	新闻可信度评估	经确认的新闻内容、联网选项	评分、风险等级、理由和状态	证据不足或模型降级时明确标记能力边界
FR-U04	游客/注册用户	结果与证据查看	当次检测结果	风险点、关键词、建议、有效证据和排除证据	相似度仅用于召回、补充判断和展示
FR-U05	注册用户	历史与重新评估	本人记录、重评请求	分页历史、详情和新评估记录	仅本人访问；重评不得覆盖旧记录
FR-U06	注册用户	检测报告生成	已保存的本人检测记录	PDF 报告或失败提示	生成失败不改变原检测记录

续表 2-1

编号	角色/主体	功能需求	主要输入	主要输出	异常或边界要求
FR-A01	管理员	知识库管理	知识条目及同步操作	业务记录、同步状态和恢复结果	失败原因可查；支持单条重试和全量重建
FR-A02	管理员	Prompt 模板管理	模板内容、状态和默认设置	可用模板及变更结果	无效或停用模板不得设为默认模板
FR-A03	管理员	高风险复核	高风险记录、状态、备注和公开设置	复核状态与公开状态	风险等级仅作为复核线索，不等同人工结论
FR-A04	管理员	用户、检测和报告管理	查询条件与授权管理操作	列表、详情和操作结果	管理接口仅管理员访问并保留必要审计记录
FR-A05	管理员	统计与日志	时间范围、统计维度和日志条件	聚合统计和分页日志	统计口径来自业务数据；日志不得记录密钥

续表 2-1

编号	角色/主体	功能需求	主要输入	主要输出	异常或边界要求
FR-S01	智能评估支撑	多源候选获取	新闻文本、本地索引、联网选项	本地及按需补充的网络候选	联网失败保留本地路径, 不据此判定新闻不可信
FR-S02	智能评估支撑	候选标准化与去重	多源候选证据	统一格式、规范化URL、唯一候选标识和稳定顺序	重复候选合并; 来源顺序不得影响处理规则
FR-S03	智能评估支撑	证据仲裁	全部候选及新闻内容	有效证据、排除证据和逐条仲裁理由	两类集合应完整且不重复覆盖候选
FR-S04	智能评估支撑	契约校验与重试	结构化仲裁结果	校验结果、一次聚焦重试和异常摘要	重试后仍不合格的候选不得参与证据评分
FR-S05	智能评估支撑	分支式评分与降级	模型状态、有效证据状态和规则分	对应评分分支、风险等级和降级状态	模型不可用时仅采用确定性规则, 不虚构证据质量
FR-S06	智能评估支撑	评估过程持久化	候选、仲裁、评分和异常信息	可追溯检测记录及契约版本	持久化失败回滚并返回明确错误, 不报告伪成功

2.2.1 新闻输入与内容预览需求

系统应支持手工输入和 URL 提取预览两条路径。手工输入至少包括新闻标题与正文, 并允许补充来源和发布时间; URL 路径先提取标题、正文、来源与发布时间形成预览, 不直接触发检测。用户确认或修订预览内容后, 系统才接收最终文本进入评估流程。

系统应在提交前检查标题和正文的必要性、文本长度和基本格式, 不允许空白正文进入检测。URL 提取失败时应返回可理解的原因, 保留用户输入的原链接, 并允许重新尝试或切换为手工输入。上述需求由 FR-U01 和 FR-U02 追踪。

2.2.2 新闻可信度评估与结果查看需求

用户提交经确认的新闻内容后, 系统应完成候选证据获取、证据仲裁和评分分支选择, 输出可信度评分、风险等级、判断理由、风险点、关键词和建议。结果页面还应区分有效证据与排除证据, 给出证据取舍理由, 并显示证据不足、联网失败、仲裁失败或模型降级等状态。

相似度可以随候选证据展示, 也可以参与本地证据是否充足的判断, 但不得直接表述为新闻可信度分数或证据质量分。联网搜索失败不等于新闻不可信, 模型服务失败也不等于新

闻风险升高；系统应根据可用信息进入相应分支，而不是把技术异常转化为事实结论。上述需求由 FR-U03 和 FR-U04 追踪。

2.2.3 个人记录与报告需求

注册用户应能够分页查看本人历史记录和检测详情。重新评估使用原记录中的新闻输入重新执行当前评估流程，并保存为新的检测记录，以保留知识、模板或模型状态变化前后的结果，不得覆盖旧记录。

报告只能根据已经保存且用户有权访问的检测结果生成，内容应与该次检测的评分、风险等级、解释和证据一致。PDF 生成失败时应返回明确提示并清理无效派生文件，不得修改原检测记录或影响页面结果查看。上述需求由 FR-U05 和 FR-U06 追踪。

2.2.4 管理员业务管理需求

管理员应能够对知识条目执行新增、查询、修改和删除，查看派生向量的同步状态与失败原因，并对失败记录执行单条重试或全量索引重建。Prompt 模板管理应支持新增、修改、启用、停用和默认模板设置；内容无效或处于停用状态的模板不得设置为默认模板。

管理员还应能够查询和管理用户、检测记录与报告，维护高风险记录的复核状态、备注和公开状态，并查看统计分析与系统日志。知识、Prompt、用户状态、高风险复核、检测和报告等关键管理操作应保留必要审计信息。上述需求由 FR-A01 至 FR-A05 追踪。

2.2.5 智能评估支撑需求

系统应优先从本地知识库召回候选证据，并依据本地候选数量与相似度判断证据是否充足；仅在用户选择和系统配置允许时按需联网补充。联网失败时保留本地分析路径。本地与网络候选应转换为统一结构，完成 URL 规范化和重复候选处理，并为每条候选生成稳定且唯一的 `candidate_id`。候选送入分析前应采用来源中立且可复现的顺序，减少来源位置对结果的影响。

模型应对全部候选逐条给出相关性、质量、立场和取舍理由，并将候选完整且不重复地划分为有效证据和排除证据。服务端应校验 `candidate_id`、字段类型、分数范围、立场枚举以及两类集合对候选的完整覆盖，防止未知、重复、缺失或越界结果进入评分。

首次仲裁不符合契约时，系统仅针对证据仲裁执行一次聚焦重试。重试后仍不符合要求的候选不得参与证据评分，并应保存仲裁失败状态与异常摘要。系统不以模型返回的自由文本替代服务端校验，也不因候选相似度较高而跳过仲裁。

系统应根据模型服务状态和有效证据状态选择评分策略。模型可用且存在有效证据时使用包含证据质量的评分分支；模型可用但无有效证据时使用不含证据质量的分支；模型不可

用时进入确定性规则评分降级路径，不使用未经仲裁的候选证据，不虚构证据质量分，并在结果中标记降级状态和能力边界。

评估完成后，系统应保存原始候选证据、有效证据、排除证据、评分分量、仲裁状态、异常摘要和分析契约版本，使结果能够追溯到当次输入、证据取舍和评分条件。上述能力由 FR-S01 至 FR-S06 追踪。

2.3 系统业务流程分析

2.3.1 新闻输入与 URL 预览流程

手工输入路径由用户填写标题、正文、来源和发布时间，系统校验后形成待评估内容。URL 路径由用户提交公开网页地址，系统在通过协议、地址和响应限制检查后提取内容，并将标题、正文、来源和发布时间返回为预览。两条路径最终都以用户确认的文本作为正式检测输入。

链接提取失败时，交互界面应保留原链接并展示失败原因，用户可以再次尝试或改用手工输入；提取结果正文为空或经用户删除为空时，不得进入检测流程。URL 预览与正式检测应分为两个阶段，以避免网页解析误差直接形成检测记录。

2.3.2 新闻可信度评估主流程

新闻可信度评估从内容校验开始。系统先执行本地候选召回并判断本地证据是否充足，在允许且需要时联网补充；随后统一候选格式、规范化 URL、处理重复项、生成稳定候选标识并形成来源中立顺序。模型对候选执行分析和证据仲裁，服务端完成契约校验，必要时聚焦重试一次。

系统根据模型是否可用以及是否存在有效证据选择对应评分分支，再生成风险等级、理由、风险点、建议和状态说明，最后保存候选、仲裁、评分和异常信息。该流程强调先仲裁、后评分，检索命中本身不构成可信度判断。主流程及其判断分支如图 2-2 所示。




图 2-2 新闻可信度评估业务流程图

2.3.3 异常处理与降级流程

本地证据不足时，系统在满足授权和配置条件后尝试联网补充；未获授权、联网失败或搜索无结果时，继续使用现有本地候选并标记证据状态。联网失败仅表示补充能力不可用，不能据此判定新闻不可信。

模型输出结构不合格、候选划分不完整或字段越界时，服务端拒绝该次仲裁并聚焦重试一次；重试仍失败时，相关候选不参与证据评分。模型服务整体不可用时，系统进入确定性规则评分降级路径，结果必须标记模型降级和证据能力边界。模型失败不应自动提高新闻风险等级。

检测数据持久化失败时，系统应回滚当前写入并返回明确错误，不得向用户报告检测已成功保存。报告生成失败发生在已保存结果之后，只影响报告派生文件与报告状态，不得改变原检测记录。异常分支应保存必要的错误摘要，以支持问题定位和后续测试。

2.3.4 知识库维护与向量同步流程

知识维护以业务数据库中的知识记录为事实源，向量索引由知识数据派生并用于语义召回。管理员新增、修改或删除知识条目时，系统应校验业务数据、执行相应业务记录与向量索引维护，并记录同步状态；两类存储之间不宣称跨存储强事务或始终一致。

同步失败时，系统应记录失败原因并根据操作阶段执行回滚或补偿，支持对单条记录重试以及在需要时全量重建索引。检索命中向量后仍应以业务事实源确认条目有效性，从而降低孤立或过期索引进入候选池的风险。维护与恢复流程如图 2-3 所示。




图 2-3 知识库维护与向量同步流程图

2.3.5 高风险复核与报告管理流程

系统将达到高风险条件的检测记录提供给管理员作为复核线索。管理员可以查看新闻内容、评估解释和证据，维护复核状态、备注及公开状态。自动风险等级不能直接替代人工复核结论，未满足公开条件的记录不得通过公开页面展示。

报告管理以已保存检测记录为依据。注册用户只能为本人记录生成和下载报告，管理员可在授权范围内查看全局报告信息。报告生成失败时保留原检测记录和页面结果，不以空文件或伪成功状态代替真实失败。

2.4 系统非功能需求分析

非功能需求用于约束系统在安全、可靠、数据一致、可解释、可维护、可扩展、性能控制和审计方面的质量属性。表 2-2 给出可追踪要求及验收方式，不预设尚未在目标环境验证的并发量、毫秒级响应时间、系统可用率或高可用指标。

表 2-2 系统非功能需求表

编号	需求类别	具体要求	验收方式
NFR-S01	权限安全	管理接口仅管理员访问； 个人历史、详情和报告仅记录所有者或授权管理员访问。	以游客、普通用户和管理员执行越权接口测试。
NFR-S02	输入安全	账号、分页、枚举和检测文本在接口边界校验；正文和候选数量设置合理上限。	执行空值、超长文本、非法枚举和边界值测试。
NFR-S03	URL 访问安全	仅允许 HTTP/HTTPS；拒绝本机、私有、链路本地和保留地址；每次重定向后重新校验。	使用受限地址、协议和重定向链模拟测试。

续表 2-2

编号	需求类别	具体要求	验收方式
NFR-S04	敏感信息安全	数据库、令牌、模型和搜索服务密钥不得写入代码、论文或普通日志。	检查源码、配置样例、论文和日志输出。
NFR-R01	外部服务可靠性	网页抓取、联网搜索和模型调用设置超时；单项失败不得被解释为新闻风险升高。	模拟超时、无结果、网络错误并检查降级状态。
NFR-R02	模型输出可靠性	模型输出须经字段、类型、范围、枚举和候选完整性校验，必要时仅聚焦重试一次。	注入缺字段、越界分值、未知标识和重复划分结果。

续表 2-2

编号	需求类别	具体要求	验收方式
NFR-D01	数据一致性	业务数据库作为事实源，向量索引作为派生数据；记录同步状态并提供补偿、重试和重建路径。	模拟向量写入、删除及数据库提交失败并检查恢复状态。
NFR-E01	可解释性	结果同时给出评分、等级、理由、风险点、建议、证据取舍和降级说明。	检查正常、证据不足和模型失败三类结果。
NFR-M01	可维护性	评估、知识、Prompt、报告、统计和审计职责边界清晰；外部配置集中管理。	审查模块边界、配置来源和异常日志。

续表 2-2

编号	需求类别	具体要求	验收方式
NFR-X01	可扩展性	新增知识来源、新闻类别或外部服务适配时，尽量保持稳定业务入口和需求编号。	通过设计审查和替换适配配置验证影响范围。
NFR-P01	数据查询性能	列表接口使用分页，统计尽量在数据库层聚合，避免一次返回无界数据。	检查接口分页参数、返回规模和统计查询实现。
NFR-P02	外部调用控制	网页响应体、新闻正文和候选数量设置上限；抓取、搜索和模型调用具有超时与失败退出。	执行超大响应、超量候选和超时模拟测试。
NFR-A01	审计性	知识、Prompt、用户、高风险、检测和报告等关键管理操作形成可查询审计记录。	执行关键管理操作并核对操作者、动作、模块和时间。

验收时应重点覆盖权限越权、恶意或异常 URL、超长输入、外部服务超时、模型契约错误、向量同步失败、报告失败和数据库写入失败等场景。列表查询应采用分页，统计尽量在数据库层聚合；网页响应体、新闻正文和候选证据数量应设置上限，避免无界输入和外部调用长期占用资源。

安全要求还包括每次 URL 重定向后重新进行地址检查，密钥不得进入代码、论文和普通日志。上述异常分支可通过模拟失败和边界输入进行验证，验收结论应以实际测试记录为准。

2.5 本章小结

本章明确了系统作为新闻可信度辅助评估与风险提示工具的业务边界，区分游客、注册用户和管理员三类角色，并从用户功能、管理员治理和智能评估支撑三个方面定义了可追踪功能需求。系统输出不替代专业事实核查，证据不足或外部能力不可用时需暴露不确定性和降级状态。

本章还规定了 URL 预览、证据仲裁、异常重试、规则降级、知识向量恢复、高风险复核和报告管理流程，并以 NFR 编号约束安全、可靠、解释、维护、性能控制和审计要求。这些编号为后续总体设计、系统实现和测试验收建立统一依据。

第3章 系统开发环境与关键技术

3.1 技术选型目标与总体说明

本系统的技术选型围绕新闻可信度辅助评估的完整业务链展开。系统既需要接收新闻文本与URL内容，又需要保存用户、知识、检测、证据、报告和日志等结构化数据；既要从本地知识库召回语义相关候选，又要在本地覆盖不足时补充近期网络信息；同时还要调用大语言模型完成结构化分析与证据仲裁，并保留候选证据、评分过程和异常状态，以支持结果解释、管理复核和问题追踪。

技术选型不是依据框架流行程度决定，而是结合系统业务需求、硬件条件、部署复杂度、开发成本和数据追溯要求综合确定。在课程设计规模和现有开发条件下，系统采用前后端分离架构，以Vue3构建交互界面，以FastAPI组织接口和业务服务，以MySQL保存业务事实，以Chroma维护可重建的语义向量索引，并通过远程API使用Embedding、大语言模型和联网搜索能力。

该组合的目标并非把智能服务置于业务约束之外，而是形成职责清晰的模块边界：关系数据库负责确定性数据，向量检索负责候选发现，大语言模型负责语义判断，服务端负责结构、范围、权限和事务约束。远程模型调用降低了本地部署大规模权重的计算资源要求，但同时引入网络时延、服务可用性和调用配置依赖，因此系统还需要以依赖锁定、环境变量、数据库迁移、模型名称、向量维度和索引重建规则支撑可复现运行。

3.2 系统开发与运行环境

3.2.1 硬件环境

系统在 64 位 Windows10 专业版环境中完成开发与联调，开发计算机采用 Intel(R)Core(TM)i7-10870H 处理器，具有 8 个物理核心、16 个逻辑处理器和约 16GB 内存。该配置属于常规个人开发环境，主要承担浏览器、Vue 前端开发服务器、FastAPI 后端、MySQL、Chroma 持久化客户端及测试工具的本地运行，不作为高性能实验平台表述。

大语言模型分析和正式文本 Embedding 均通过远程 API 调用，本地不下载或加载大规模模型权重。这一方式降低了显存、内存和模型部署维护成本，使普通开发计算机能够完成系统联调；同时，评估链路会受到网络质量、外部服务限额、接口超时和凭据配置的影响，因而外部能力不可用时必须返回明确状态，而不能把技术故障解释为新闻风险。

3.2.2 软件环境与依赖约束

表 3-1 区分本机实际安装版本、项目声明约束和锁文件解析版本。本机版本用于说明本次开发与验证环境，项目声明用于约束安装范围，二者不能相互替代。其中，requirements.txt 没有声明 Python 兼容范围，因此 Python 3.14.2 仅是当前本机事实，不构成系统最低版本要求。

表 3-1 系统开发与运行环境

项目	开发环境或版本	约束来源	主要用途
操作系统	Windows10 专业版 64 位	本机系统信息	前端、后端、数据库和浏览器联调
Python	本机 3.14.2；项目未 声明兼容范围	python --version、 requirements.txt	运行 FastAPI 后端 及自动化脚本
Node.js 与 npm	Node.js 22.22.3、 npm 10.9.8	本机命令输出	前端依赖安装、开 发服务和生产构建
MySQL	服务端 8.0.26	SELECT VERSION()	保存结构化业务事 实数据
Git	2.49.0.windows.1	本机命令输出	代码与文档自动化 脚本版本管理

前端框架的实际安装版本由 package-lock.json 确定，后端多数核心依赖在 requirements.txt 中使用精确版本，但 Chroma、BeautifulSoup4 和 APScheduler 仍采用版本范围，Pydantic 也未作为直接依赖单独锁定。因此，复现环境时应同时保存本机验证结果和依赖解析清单，不能仅凭顶层依赖文件推断全部传递依赖版本。

3.3 Web应用开发技术

3.3.1 Vue3与前端组件化技术

Vue3 以响应式数据和组件化机制组织前端界面。新闻输入页中的标题、正文、来源、发布时间和联网选项可与表单状态绑定，检测过程中的提交、加载、成功、证据不足和降级状态能够随响应数据更新；评分总览、风险标签、有效证据、排除证据和管理员统计图表则可拆分为职责明确的展示组件。组件化减少了用户端与管理端在分页、空状态、风险等级和操作反馈方面的重复实现。

项目锁文件解析出的 Vue 版本为 3.5.35。Vite6.4.3 负责开发服务器、模块加载和生产构建，并在开发阶段将“/api”请求代理到本地后端。Element Plus2.14.1 提供表单、表格、分页、对话框和状态标签等管理型界面组件；Vue Router4.6.4 负责页面导航与路由访问控制；Pinia2.3.1 保存当前用户、令牌和会话恢复状态；Axios1.16.1 统一 HTTP 基础地址、令牌附加、超时和 401 处理；ECharts5.6.0 用于管理统计可视化。上述组件共同服务于业务交互，不分别承担可信度判断。

Vue3 与 React 均能够实现前后端分离应用。本系统包含较多表单、管理表格、状态标签和结果展示组件，在课程设计规模和现有开发条件下，Vue3 与 Element Plus 能够降低基础界面和交互组件的实现成本。该选择属于项目条件下的适配性选择，不代表其在所有场景下优于其他前端框架。

前端的路由守卫和状态管理主要改善导航体验与会话展示，不能替代后端权限校验；Axios 响应拦截能够统一处理常见错误，但不能消除网络失败或服务端业务异常。因此，可信度评分、资源归属和管理员权限仍由后端确定，前端只负责提交参数和呈现后端返回状态。

3.3.2 FastAPI与后端接口技术

FastAPI0.111.0 基于 Python 类型标注定义接口输入、输出和依赖关系，并自动生成 OpenAPI 文档，适合在前后端分离条件下统一接口契约与联调入口。Pydantic 负责将 JSON 请求转换为类型化对象，校验字段类型、长度和枚举范围；当前环境安装 Pydantic2.13.4，但该版本来自依赖解析，requirements.txt 未直接锁定。

FastAPI的依赖注入机制用于组合数据库会话、当前用户、管理员角色和可选游客身份，使认证与权限逻辑能够在路由间复用。Uvicorn0.30.1运行ASGI应用，为HTTP接口和应用生命周期管理提供运行容器。SQLAlchemy则由数据访问层和业务层使用，负责关系模型映射、查询构造与会话事务。

在候选方案中，Flask轻量灵活，但类型模型、依赖注入和接口文档通常需要额外组合；Django内置认证、管理后台和ORM等能力较完整，但对以API和智能服务编排为主、已有独立Vue前端的项目相对较重；FastAPI能够以较少配置提供类型校验、依赖注入和OpenAPI文档，更符合本系统的接口组织方式。

需要指出的是，Pydantic校验只覆盖接口边界，不能替代数据库的非空、唯一、外键和索引约束；SQLAlchemy ORM能够组织关系数据访问，但不能自动解决MySQL、Chroma和报告文件之间的一致性。数据库会话何时提交、何时回滚以及外部存储失败时如何补偿，仍需由业务层明确控制。

3.4 关系数据存储与结构版本管理

3.4.1 MySQL业务数据存储

MySQL保存系统的确定性业务数据，包括用户信息、知识条目、检测记录、有效证据快照、Prompt模板、报告记录、系统日志和定时采集任务执行摘要。上述数据具有清晰的实体关系、查询条件和生命周期，需要依靠主键、外键、唯一约束、事务和索引维持业务语义。

关系数据库适合本系统的主要原因在于：用户与检测记录、检测与证据、检测与报告之间可以通过主外键表达；用户名、邮箱和报告关联可使用唯一约束；列表查询可以通过条件、分页和索引控制返回规模；统计页面所需的趋势、分布和数量可以在数据库层聚合；同一业务事务中的关系记录能够统一提交或回滚。

MySQL是系统业务事实源，Chroma只保存由知识条目派生的语义向量索引。向量检索命中后仍需依据knowledge_id回查MySQL，以确认识知条目是否存在并读取其当前内容。这一职责划分避免把可能滞后的向量元数据当作最终业务事实，也使向量索引能够在损坏或模型变更后重新构建。

3.4.2 SQLAlchemy与Alembic

SQLAlchemy2.0.31将关系表映射为Python模型，并通过Session维护查询、对象状态和事务边界。应用层校验用于给出面向业务的错误信息，数据库约束负责阻止不满足结构条件的数据落库；两者协同能够减少仅依赖单层校验造成的数据漂移。

Session不会自动决定完整业务流程的原子范围。新闻检测需要在保存检测记录与有效证据时控制同一数据库事务，知识库维护则还涉及数据库之外的Chroma操作。对于后者，SQLAlchemy只能保证MySQL内部提交与回滚，跨存储顺序控制、同步状态和补偿恢复必须由服务层实现。

Alembic1.13.2用于记录数据库模式的演进。项目迁移从初始表结构开始，依次加入高风险复核字段、系统日志、业务更新时间、证据网络来源字段、采集任务表和检测分析载荷；运行时可以检查当前修订是否到达迁移头。与手工修改数据库相比，迁移脚本能够保留变更顺序和升级入口，更有利于在新环境中重建一致表结构。

迁移机制本身仍依赖正确执行。若部署时未运行升级命令、数据库权限不足或迁移脚本与ORM模型不同步，应用仍可能出现结构不匹配。因此，可复现环境应同时记录迁移头、执行状态和实际数据库版本，而不能只保存ORM代码。

3.5 文本Embedding与向量语义检索

3.5.1 文本Embedding原理

文本Embedding将不同长度的自然语言文本映射为固定维度的实数向量，使计算机能够在统一向量空间中比较语义关系。在RAG系统中，知识条目预先向量化形成索引，待评估新闻在查询时使用同一模型生成查询向量，再依据向量距离发现语义邻近候选。该方法为知识密集型生成任务提供外部检索入口[2][10]。

同一索引中的新闻查询与知识条目必须使用相同Embedding模型、相同向量维度和一致的文本预处理规则。若一部分向量由旧模型生成、另一部分由新模型生成，即使维度相同，其空间含义也未必可比较；若维度不同，向量库则无法完成同一集合内的距离计算。

项目正式配置采用阿里云DashScope兼容接口的text-embedding-v4模型，输出维度配置为1024。新闻查询与知识文本均由后端Embedding服务调用远程API生成向量，本地只保存结果索引。模型名称、服务地址、API密钥、超时和维度均由配置读取，其中密钥不写入代码或论文。

代码还保留Hash向量测试模式。Hash向量仅用于测试向量写入、查询和流程连通性，不具备正式语义表示能力，不能作为系统正式RAG检索和实验评价结果。该模式的意义是隔离外部Embedding服务对工程测试的影响，而不是提供与语义模型等价的替代方案。

Embedding模型或向量维度发生变化后，必须重新生成全部知识向量并重建Chroma集合。单纯修改环境变量而继续使用旧索引会造成维度错误或语义空间混用，破坏检索可解释性和实验可复现性。

3.5.2 余弦相似度计算

系统使用余弦空间衡量查询向量与知识向量的方向接近程度。设待评估新闻的查询向量为 q ，知识条目的文本向量为 d ，则二者的余弦相似度定义如式（3-1）所示。

$$\text{sim}(q, d) = \frac{q \cdot d}{\|q\|_2 \|d\|_2} \quad (3-1)$$

式中， q 表示待评估新闻的查询向量， d 表示知识条目的文本向量， $\text{sim}(q, d)$ 表示二者在向量空间中的语义接近程度； $q \cdot d$ 为向量点积， $\|q\|_2$ 和 $\|d\|_2$ 分别为两个向量的二范数。

余弦相似度关注向量方向而非文本长度，适合在统一Embedding空间中比较不同长度文本。Chroma返回余弦距离后，系统可将其转换为便于展示的相似度值，但该数值仍只描述向量空间关系。

相似度高只表示两个文本在模型表示空间中较为接近，不代表候选材料真实，也不代表候选一定支持待评估新闻。语义相近的内容可能是重复转载、辟谣材料、反驳观点或同一主题下的无关细节，因此不得把相似度直接等同于新闻可信度。

本系统将相似度用于候选召回、本地证据是否不足的判断和结果展示，候选是否有效仍需结合业务数据回查、来源信息和大语言模型证据仲裁确定。该边界使向量检索承担“发现相关材料”的职责，而不越权承担事实裁决。

3.5.3 Chroma向量检索

Chroma作为本地持久化向量索引，当前环境安装版本为1.5.9，requirements.txt将其约束在1.0.0及以上、2.0.0以下。系统使用PersistentClient访问配置化目录，在knowledge_items集合中保存知识文本向量、knowledge_id及必要的轻量元数据，集合空间配置为cosine。

查询时，待评估新闻先生成查询向量，再由Chroma获取Top-K语义候选。返回结果包含向量标识、文档、元数据和距离，服务端依据元数据中的knowledge_id回查MySQL；数据库中已删除或不存在的条目不能直接进入后续评估。由此，Chroma负责近邻搜索，MySQL负责确认业务有效性。

向量索引属于可重建的派生数据。知识内容变化、同步失败、集合损坏或者Embedding模型和维度变更时，可以根据MySQL中的知识条目重新生成索引。该方式不能自动消除双存储中间状态，但为恢复和一致性检查提供了明确方向。

表3-2从项目规模、部署成本和职责边界比较主要候选方案。比较结论用于说明当前系统的适配性，不构成对其他技术在更大规模、分布式或不同团队条件下的普遍优劣判断。

表3-2 主要技术候选方案比较

技术类别	候选方案	主要特点	本系统选择依据
前端框架	Vue3	响应式与组件化机制成熟, 可与Element Plus直接组合	表单和管理界面较多, 现有开发条件下实现成本较低
前端框架	React	生态广、组合自由度较高, 需要自行选择较多配套方案	具备可行性, 但本项目已有Vue技术栈与组件库基础
后端框架	FastAPI	类型标注、依赖注入、Pydantic和OpenAPI集成度高	适合前后端分离接口及智能服务编排
后端框架	Flask	核心轻量、扩展灵活	类型契约、依赖注入和文档通常需要额外组合
后端框架	Django	内置ORM、认证和管理能力完整	对已有独立前端且以API编排为主的课程项目相对较重

续表3-2

技术类别	候选方案	主要特点	本系统选择依据
向量检索	Chroma	支持本地持久化、 集合与元数据管理，部署 较简单	当前知识规模和单 机条件下便于快速集成 与重建
向量检索	FAISS	偏向底层高效向量 检索能力	需自行补充持久 化、业务元数据和管理能 力
向量检索	Milvus	面向更大规模和分 布式向量检索场景	扩展能力较强，但 当前项目部署复杂度和 运维成本偏高

续表3-2

技术类别	候选方案	主要特点	本系统选择依据
Embedding部署	远程API	无需本地加载模 型，依赖网络、配额和外 部服务	符合本机资源条 件，并可配置模型与维度
Embedding部署	本地模型	数据与推理可本地 控制，需要模型权重和计 算资源	本项目未部署本地 模型，不作为已实现方案

3.6 RAG与大语言模型证据分析技术

3.6.1 RAG工作机制

检索增强生成（Retrieval-Augmented Generation，RAG）在生成前引入外部知识，使模型能够依据检索材料处理知识密集型任务[2][10]。在新闻可信度辅助评估中，RAG的价值不是替模型直接给出真假标签，而是建立从待评估新闻到可追溯候选证据的上下文通道。系统将其划分为检索、增强以及生成与仲裁三个环节。

（1）**检索阶段**。系统将新闻标题与正文组织为查询文本并向量化，从本地Chroma索引召回Top-K候选；当本地候选不能满足覆盖需要且用户允许联网时，再调用网络搜索补充

近期信息。本地检索提供可维护、可重建的知识基础，联网补充用于缓解知识库时效性和覆盖范围限制。

(2) 增强阶段。多源候选需要转换为统一数据结构，规范化URL，处理强身份重复项，生成唯一candidate_id，并采用来源中立且可复现的顺序组织模型上下文。增强阶段的重点是保留来源、标题、摘要和候选标识，使模型引用能够追溯到输入候选，而不是把检索结果直接拼接为不可校验的自由文本。

(3) 生成与仲裁阶段。大语言模型分析待评估新闻，并对每条候选的相关性、质量和支持、反驳或中立立场作出判断，形成有效证据与排除证据。服务端随后检查候选引用、字段结构、分值范围和候选覆盖情况，将生成式输出转换为受确定性规则约束的业务数据。

已有事实核查研究表明，检索与证据推理需要同时考虑支持材料和反驳材料[7][8]。因此，系统不只展示命中的相似新闻，还保留排除原因和立场判断，以避免把“检索到”误写成“已经证实”。

RAG能够提供外部上下文和证据线索，但不能自动保证结果正确。错误召回、来源质量不足、重复转载和冲突证据仍可能影响结果，因此还需要证据仲裁和程序校验。第3章只说明上述技术机制，具体触发条件、评分分支和持久化字段在系统设计与实现章节中给出。

3.6.2 DeepSeek语义分析与证据仲裁

系统通过DeepSeek兼容的对话补全接口调用远程大语言模型，当前开发环境中的DEEPSEEK_MODEL配置为deepseek-v4-pro。请求关闭流式输出，使用较低温度并声明JSON对象响应格式，以提高结构化结果的稳定性；模型名称、服务地址、密钥和超时通过环境配置读取。

DeepSeek在系统中承担新闻主题与风险表达分析、可信度语义分量生成、候选证据相关性、质量判断、支持或反驳立场判断，以及理由、风险点、关键词和建议生成。这些任务利用大语言模型的语义理解与文本生成能力[11]，但模型不是业务事实源，也不直接写入最终业务状态。

模型返回的JSON并非天然可信数据。大语言模型可能产生幻觉或与事实不一致的内容[3][12]，也可能遗漏候选、重复引用候选、引用不存在的candidate_id、给出越界分值或非法枚举；即使JSON语法正确，其语义判断也可能受证据质量、提示方式和任务类型影响[5]。

因此，系统遵循“模型负责语义判断，程序负责业务约束”的分工。Prompt要求模型只引用给定候选标识并输出固定结构，服务端继续执行必需字段、标识合法性、完整覆盖、重

复划分、分值范围和立场枚举校验。结构校验能够限制异常输出进入评分，但不能单独证明模型的事实判断正确。

当模型调用失败或结构化结果无法满足业务契约时，系统应显式进入降级或仲裁不完整状态，保留错误摘要并切换到可用的确定性路径，不能伪造正常模型结果。这一边界使外部智能服务的失败可被用户和管理员识别，也便于后续复核。

3.6.3 联网搜索与近期信息补充

项目接入博查Web搜索服务，用于补充本地知识库尚未覆盖的近期信息。联网搜索不是每次评估的必经步骤，是否调用由本地证据状态、用户联网选项和系统配置共同决定，避免无条件增加网络依赖与调用成本。

搜索结果需要转换为与本地候选一致的标题、摘要、来源、URL、发布时间和候选标识结构，再与本地候选共同进入证据仲裁。来自互联网只说明候选来源，不自动代表内容真实、权威或与待评估新闻立场一致。

联网搜索失败时，系统保留已有本地检索路径并记录补充能力不可用；搜索失败不能被解释为新闻不可信。网络候选仍需经过URL规范化、重复处理和模型仲裁，才能作为有效证据参与后续分析。

3.7 业务支撑与可复现性技术

3.7.1 网页解析、任务调度与报告生成

BeautifulSoup4用于解析网页标题、正文、来源和发布时间等内容，当前环境版本为4.12.3。网页结构具有较强差异性，解析结果可能缺失或包含噪声，因此URL路径先返回预览并允许用户确认或修订，提取失败或正文无效时不应直接提交检测。

APScheduler3.11.2用于随应用生命周期注册周期性新闻采集任务，为知识库更新提供调度支撑。调度器只负责按配置触发任务，搜索、抓取、去重、入库和向量同步仍由业务服务完成；缺少搜索凭据或关闭采集配置时，调度能力可以停用而不阻断Web应用启动。

Jinja2 3.1.6将检测数据渲染为HTML报告模板，xhtml2pdf0.2.17把HTML转换为PDF文件。报告属于检测结果的派生输出，生成失败不应破坏原检测记录。BeautifulSoup4、APScheduler、Jinja2和xhtml2pdf均属于业务支撑技术，不参与新闻可信度判断算法。

3.7.2 配置、依赖与环境管理

前端依赖由package.json声明版本范围，package-lock.json固定本次安装解析出的实际版本。后端依赖由requirements.txt管理，其中FastAPI0.111.0、Uvicorn0.30.1、SQLAlchemy2.0.31、

Alembic1.13.2、Jinja23.1.6和xhtml2pdf0.2.17使用精确版本，Chroma、BeautifulSoup4和APScheduler使用范围约束。

当前项目没有pyproject.toml、.python-version或其他文件声明Python兼容范围，也没有完整的后端传递依赖锁文件。因此，复现时除安装requirements.txt外，还应记录验证通过的Python版本和实际依赖清单；若后续需要长期维护，应补充明确的Python范围和可重复解析的后端锁定机制。

数据库结构由Alembic迁移管理，数据库地址、JWT密钥、DeepSeek和DashScope模型配置、各外部API密钥、Chroma目录和报告目录通过环境变量读取。.env.example只保留配置项名称和示例，不保存真实密钥。当前博查客户端的搜索端点仍由代码常量确定，虽然配置类读取BOCHA_API_BASE_URL，但尚未形成完整的客户端注入链，部署复现时应以当前客户端实现为准。

Embedding模型、向量维度、Chroma集合空间和已有索引必须保持一致。正式语义模式使用DashScopetext-embedding-v4与1024维向量；Hash模式只能用于流程测试。更换模型、维度或预处理规则后必须重建索引，向量目录和报告目录则应使用配置化绝对路径或可稳定解析的相对路径。

Windows与Linux在路径分隔、目录权限、字体可用性和服务启动方式上存在差异。当前开发结果只能证明Windows环境中的运行事实，迁移到Linux后仍需重新验证MySQL连接、Chroma目录权限、PDF中文字体和计划任务生命周期，不能把配置化路径直接等同于已经完成跨平台兼容验证。

表3-3汇总关键技术、系统能力、主要局限和约束方式。该映射体现了本系统对智能组件的不确定性控制：检索结果需要业务回查，网络候选需要仲裁，模型输出需要校验，派生文件失败需要与事实记录隔离。

表3-3 关键技术与系统能力对应关系

关键技术	支撑的系统能力	主要风险或局限	系统约束方式
DashScope Embedding	将新闻与知识文本 映射到统一向量空间	语义相似不等于事 实可信；依赖远程服务	固定模型与维度， 失败显式返回，变更后重 建索引
Chroma	保存派生向量并完 成Top-K候选召回	索引可能滞后、孤 立或损坏	通过knowledge_id 回查MySQL，记录同步状 态并支持重建

续表3-3

关键技术	支撑的系统能力	主要风险或局限	系统约束方式
联网搜索	补充本地知识库未 覆盖的近期信息	来源质量不一，接 口可能超时或无结果	按需调用、统一格 式、证据仲裁和本地路径 降级
DeepSeek	新闻语义分析、证 据质量与立场判断	可能幻觉、漏项、 越界或输出非法结构	固定JSON要求、服 务端契约校验和失败降 级

续表3-3

关键技术	支撑的系统能力	主要风险或局限	系统约束方式
MySQL	保存用户、知识、 检测、证据、报告与日志 等业务事实	错误事务边界或约 束缺失会造成数据异常	主外键、唯一约束、 索引及业务层提交与回 滚
Alembic	记录并执行数据库 模式版本变更	未执行迁移会导致 ORM与数据库不一致	迁移脚本、头修订 检查和部署升级流程

续表3-3

关键技术	支撑的系统能力	主要风险或局限	系统约束方式
BeautifulSoup4	解析URL页面的标题、正文和时间信息	网页结构差异导致缺失或噪声	受限抓取、预览确认和无效正文拒绝
Jinja2与xhtml2pdf	渲染HTML模板并生成PDF报告	字体、模板或文件操作可能失败	报告目录配置化，失败与原检测记录隔离

3.8 本章小结

本章从业务适配、部署成本、技术边界和可复现性角度说明了系统关键技术。Vue3与FastAPI提供Web应用基础，MySQL承担业务事实存储，SQLAlchemy与Alembic组织数据访问和结构版本；DashScope Embedding与Chroma完成语义候选召回，博查搜索补充近期信息，DeepSeek负责受证据约束的语义分析与证据仲裁；BeautifulSoup4、APScheduler、Jinja2和xhtml2pdf分别支撑网页解析、知识更新调度和报告生成。

向量相似度只能用于发现语义相关候选，大语言模型输出也不能直接视为事实结论。因此，系统还需要结合业务数据回查、候选证据组织、结构化输出校验和异常状态管理约束智能服务结果。前后端锁文件、后端依赖清单、环境变量、Alembic迁移、Embedding模型与维度以及向量索引重建规则，共同构成当前项目的可复现性基础，同时也暴露出Python范围和后端传递依赖尚未完整锁定等工程限制。

第 4 章 系统总体设计

本章在前述需求分析与技术选型的基础上，给出“智闻辨真”新闻可信度评估系统的总体设计。设计内容以当前项目代码、数据库模型、迁移文件、前后端路由和运行配置为事实依据，重点说明系统边界、模块协作、评估流程、数据组织、权限体系及异常恢复路径。与第 3 章侧重开发环境和技术选择不同，本章回答各类技术如何被组织为可运行系统；具体类、函数和关键代码将在第 5 章展开，测试环境与测试结果不在本章讨论。

4.1 系统设计目标与原则

4.1.1 系统设计目标

系统总体设计首先服务于新闻可信度评估这一核心业务。用户可以直接提交新闻标题和正文，也可以输入新闻 URL，待系统提取网页内容后进行确认和修订。后端围绕待评估新闻组织本地语义检索、按需联网补充、证据仲裁、规则评分和大语言模型分析，最终输出可信度分值、风险等级、判断理由、风险点、建议及可追溯证据。登录用户还可以查询历史记录、重新评估并生成检测报告；管理员可以维护知识库和 Prompt 模板，复核高风险记录，管理用户、检测记录和报告，并查看统计信息与操作日志。

可解释性与可追溯性是本系统区别于单次大模型问答的主要设计目标。系统不把大语言模型生成的结论直接视为事实，而是先构造具有稳定候选标识的证据集合，再要求模型对每条候选证据给出相关性、质量、立场及取舍理由。服务端继续验证候选是否被完整仲裁、分值是否处于合法范围、证据质量字段是否齐全，只有通过契约校验并进入 ranked 集合的证据才会参与综合评分。检测记录同时保存候选证据、排除证据、仲裁状态、质量状态和分析契约版本，使后续复核能够还原当时的判断依据。

系统还需要控制外部服务不确定性对主流程的影响。联网搜索失败时保留本地检索结果继续分析；模型服务失败时不使用未经仲裁的检索候选，而是退化为确定性规则评分；MySQL 与 Chroma 之间无法形成跨存储事务，因此通过同步状态、错误信息、回滚和补偿恢复降低不一致概率。上述目标使系统在课程设计规模下兼顾功能完整度、结果可解释性、配置可复现性和后续维护成本。

4.1.2 系统设计原则

系统采用前后端分离和模块化设计。Vue 3 前端负责页面导航、表单交互、状态反馈和结果展示，FastAPI 后端负责身份认证、业务规则、外部服务调用和数据持久化。前端不保

存决定可信度等级的业务规则，后端也不耦合具体页面布局，从而避免评分逻辑随界面变化而分散。

数据职责分离原则体现在 MySQL、Chroma 和报告目录的分工上。MySQL 是用户、知识条目、检测记录和审计信息的业务事实源；Chroma 只承担由知识条目派生的语义索引；HTML 与 PDF 报告保存到配置化文件目录，并在关系数据库中记录文件位置。检索命中向量后仍需根据 knowledge_id 回查 MySQL，防止失效或孤立向量直接进入评估结果。

系统遵循最小权限原则。公开页面和公开接口只提供新闻检测入口与已公开的高风险信息；历史记录、报告和独立 RAG 检索要求登录；管理端路由要求管理员身份，后端再次通过管理员依赖校验角色，避免仅依赖前端菜单隐藏形成权限空洞。对游客开放的检测接口使用可选身份依赖：无令牌时允许评估并将 user_id 保存为空，有令牌时则绑定当前有效用户。

系统同时遵循可降级、可追溯和配置分离原则。外部模型、Embedding、联网搜索、数据库连接、向量目录和报告目录均通过环境变量配置；错误分支保留明确状态，而不是用默认成功结果掩盖异常；关键管理操作写入系统日志。对于跨 MySQL 与 Chroma 的写操作，项目明确采用应用层补偿而非宣称实现分布式事务，使系统能力边界与实际实现保持一致。

系统角色与核心功能权限如表 4-1 所示。游客权限仅覆盖公开信息和一次性检测，注册用户获得个人数据能力，管理员在普通用户能力之上使用独立管理接口。

表 4-1 系统角色与功能权限表

功能	游客	注册用户	管理员
浏览首页与公开高风险信息	允许	允许	允许
提交新闻文本 /URL 预览与检测	允许，记录不绑定用户	允许，记录绑定本人	允许，记录绑定本人
查看个人历史、详情与重新评估	不允许	仅本人	可使用个人功能；另有全局管理接口
生成/下载个人检测报告	不允许	仅本人记录	可使用个人功能；管理端可查看全局报告
独立 RAG 知识检索	不允许	允许	允许
用户、检测、知识、Prompt、高风险管理	不允许	不允许	允许
统计分析与系统日志	不允许	不允许	允许

4.2 系统总体架构设计

4.2.1 系统总体架构

系统采用浏览器/服务器（Browser/Server, B/S）架构，整体由浏览器用户、Vue 3 前端、FastAPI 后端、业务服务、数据与文件存储以及外部智能服务组成。系统总体架构如图 4-1 所示。




图 4-1 系统总体架构图

浏览器中的游客、注册用户和管理员通过同一前端应用访问不同功能。Vue Router 根据路由元信息控制公开页面、登录页面和管理页面，Pinia 保存用户会话状态，Axios 负责向“/api”前缀下的 REST 接口发送 JSON 请求。FastAPI 接收请求后完成参数校验、身份依赖解析和统一异常处理，再把具体业务交给服务层。

后端业务服务覆盖检测编排、知识库语义检索、DeepSeek 分析、证据仲裁、规则与综合评分、报告生成、统计和系统日志。MySQL 保存结构化业务记录，Chroma 保存 knowledge_items 集合的向量索引，报告目录保存生成的 HTML 和 PDF 文件。外部服务包括 DeepSeek 对话模型、DashScope Embedding、博查搜索及新闻网页内容源。APScheduler 随应用生命周期启动，在配置允许且外部搜索凭据可用时触发周期性新闻采集。该架构将确定性业务数据、派生语义索引和外部智能能力分开，为异常定位和局部替换提供了清晰边界。

4.2.2 前后端交互架构

前端页面通过 Axios 访问后端 REST 接口。开发环境由 Vite 把“/api”请求代理到后端，生产环境的接口基础地址由配置决定。请求和响应主要使用 JSON；报告下载属于文件响应。后端成功响应统一包含 code、message 和 data 三个字段，HTTP 异常、参数校验异常与数据库异常也被转换为相同外层结构，前端可以集中处理成功提示、字段错误、未登录跳转和权限不足提示。

登录成功后，后端签发包含用户标识、角色和过期时间的 JWT 访问令牌。前端把令牌附加到 Authorization 请求头，后端以 Bearer 方式解析。前端路由守卫只用于改善导航体验，真正的访问控制仍由后端依赖完成：普通登录接口使用 `get_current_user`，管理接口使用 `get_current_admin`，游客检测使用 `get_optional_current_user`。这样既支持游客快速评估，又避免管理接口因前端状态被篡改而越权。

新闻 URL 输入采用“提取预览—人工确认—提交检测”的两阶段交互。提取预览接口只返回规范化后的标题、正文、发布时间和来源信息，不直接启动检测或写入检测记录。用户确认后，前端再提交最终文本。该设计既允许系统利用网页抽取减少复制成本，也把网页结构解析误差暴露给用户修订，降低错误正文直接进入后续模型分析的概率。

4.2.3 后端分层架构

后端按真实目录划分为 API、Schema、Service、CRUD、Model 和 Core 等层次，其依赖关系如图 4-2 所示。

后端分层架构图




图 4-2 后端分层架构图

API 层位于 `app/api`，负责定义路由、注入数据库会话和身份依赖、解释查询参数并组织 HTTP 响应。Schema 层位于 `app/schemas`，以 Pydantic 模型约束标题、正文、分页参数、枚举值和响应结构。Service 层位于 `app/services`，是业务复杂度的主要承载位置，包括检测主流程、证据仲裁、知识库同步、报告生成、统计和外部服务适配。CRUD 层集中封装 SQLAlchemy 查询、分页和持久化操作；Model 层定义表、主外键、唯一约束和级联关系。

Core 层提供横向基础能力，包括环境配置、JWT、数据库会话、角色依赖、内存滑动窗口限流、APScheduler 初始化和全局异常处理。Chroma 和报告文件并不通过 SQLAlchemy 模型访问，而由 Service 层的专门服务封装。总体依赖方向由上层用例向下层数据能力推进，API 层不直接编写复杂 SQL，CRUD 层也不负责模型调用和业务决策，从而把接口变化、业务变化和数据结构变化控制在不同层次。

4.2.4 数据存储与智能服务架构

MySQL 承担系统的结构化事实存储，包括用户、知识条目、检测记录、有效证据、Prompt 模板、报告、系统日志和采集任务。Chroma 中的向量、文档和元数据均由知识条目派生，不作为独立业务事实源。知识新增或修改后，系统构造包含标题、正文、类别、摘要、关键

词、真伪标签和辟谣说明的文本，调用 DashScope 的 text-embedding-v4 生成 1024 维向量，再以 knowledge:<id>作为向量文档标识写入 knowledge_items 集合。

DeepSeek 在系统中的职责是受候选证据约束的语义分析，而非替代数据库或直接决定最终等级。系统向其提供规范化新闻和候选证据，要求返回新闻可信度分量、理由、风险点、建议、证据质量以及逐条仲裁结果。博查搜索只在本地证据不足且用户允许联网时补充候选信息，失败不阻断本地 RAG 路径。新闻网页则由受限抓取器提取内容，抓取结果须经用户确认后才进入检测。上述分工使模型生成、语义召回和结构化持久化各自承担单一职责。

4.3 系统功能模块设计

系统功能由六个相互协作的模块组成，模块关系如图 4-3 所示。




图 4-3 系统功能模块图

表 4-2 概括各模块的服务对象、输入、主要处理和输出。模块划分覆盖用户端评估、管理端治理、数据统计与审计，也保留了知识持续更新和向量恢复路径，能够反映项目从单一模型调用扩展为完整 Web 系统的实际工作量。

表 4-2 系统主要功能模块说明表

功能模块	服务对象与输入	主要处理	主要输出
用户认证与个人中心	游客、注册用户； 账号、密码与会话令牌	注册、登录、令牌校验、账户状态检查、会话恢复	用户信息、访问令牌、个人页面状态
新闻可信度评估	游客和用户；新闻文本或 URL 确认文本	语义检索、联网补充、证据仲裁、规则与综合评分	分值、等级、理由、风险点、建议和证据

功能模块	服务对象与输入	主要处理	主要输出
检测记录与报告	登录用户；记录 ID、筛选条件	历史查询、详情、重新评估、模板渲染和 PDF 生成 条目维护、	检测历史、详情、HTML/PDF 报告
知识库与新闻采集	管理员、调度器；知识条目或采集配置	Embedding、Chroma 同步、单条重试、全量重建、定时采集	知识记录、同步状态、采集任务记录
管理员业务管理	管理员；管理筛选和操作请求	用户启停、检测管理、Prompt 管理、高风险复核与公开控制	管理列表、详情和操作结果
数据统计与系统日志	管理员；时间范围和统计维度	聚合趋势、分布、关键词、活跃度并记录管理行为	统计数据、审计日志

4.3.1 用户认证与个人中心模块

该模块面向游客和注册用户。注册输入包括用户名、密码和可选邮箱，服务端完成字段校验、重复性检查和 bcrypt 密码哈希；登录时验证密码、账户状态并签发 JWT。个人中心和历史记录要求有效登录状态，前端恢复本地会话后仍会请求当前用户接口确认令牌有效性，避免仅凭本地缓存判断身份。

模块输出包括当前用户基本信息、角色、状态和访问令牌。它向新闻检测模块提供可选用户身份，向历史和报告模块提供强制用户身份，并向管理端提供角色基础。账户被禁用后，即使已有令牌尚未过期，后端依赖仍会根据数据库中的 status 拒绝访问。

4.3.2 新闻可信度评估模块

该模块是系统核心，输入为标题、正文、来源、发布时间和是否允许联网搜索等信息。主要处理包括文本清洗、关键词提取、Chroma 召回、本地证据充分性判断、博查补充、多源候选整理、DeepSeek 分析、证据契约校验、规则评分、综合评分和风险等级映射。输出不仅包含最终结论，还包含构成结论的有效证据、模型理由、规则命中项和降级状态。

该模块与知识库模块共享向量检索能力，与 Prompt 模块读取当前默认模板，与记录模块共同完成持久化，与高风险模块共享风险等级与高风险标识。其创新点集中体现在“先仲裁、后计分”的证据治理、来源中立的候选顺序、服务端重算证据质量分和按证据可用性切换的分支式评分。

4.3.3 检测记录与报告模块

检测完成后，系统保存输入快照、各评分分量、最终等级、分析载荷和有效证据。登录用户可以按分页条件查询自己的历史记录，查看详情、删除记录或在保留原始输入的基础

上重新评估。游客检测记录的 `user_id` 为空，不进入登录用户的个人历史；游客结果页用于承接当次检测数据，持久化详情接口仍要求登录身份。

报告模块以检测记录为输入，通过 Jinja2 模板生成 HTML，再调用 xhtml2pdf 生成 PDF。reports 表对 `detection_id` 设置唯一约束，使一条检测记录最多对应一条报告记录。报告生成与检测结果展示相互独立，PDF 生成失败不会改变既有检测结论，用户仍可以查看页面结果。

4.3.4 知识库与新闻采集模块

知识库模块面向管理员，负责知识条目的新增、查询、修改、删除、单条向量化和全量索引重建。每条知识记录同时保存 `vector_id`、`vector_sync_status` 和 `vector_sync_error`，用于表明派生向量的同步状态。检索返回 Chroma 候选后，服务端依据 `knowledge_id` 重新读取 MySQL 条目并补充摘要和同步状态，防止向量元数据替代业务数据。

新闻采集由 APScheduler 和 news_crawler 服务执行。调度器根据环境配置注册周期任务，博查搜索获取候选网页，安全抓取器提取正文，服务完成重复检查、知识条目创建和可选向量化，并把执行统计写入 `crawl_tasks`。当前项目没有采集任务前端页面，也没有采集任务 REST 接口，因此本章只把它作为后台调度能力描述，不虚构人工管理入口。

4.3.5 管理员业务管理模块

管理员模块覆盖用户、检测记录、知识库、Prompt 模板、高风险新闻和报告管理。用户管理支持列表查询、用户启用和禁用，后端还保留角色更新接口；检测管理支持全局记录筛选、详情和删除；Prompt 管理支持新增、修改、启停和设置默认模板；高风险管理支持复核状态、是否公开和管理员备注维护；报告管理支持列表与详情查询。

所有管理接口统一依赖 `get_current_admin`。前端 AdminLayout 和路由守卫用于限制页面入口，后端角色校验构成最终安全边界。管理员操作与系统日志服务联动，以用户标识、动作、模块、描述和 IP 地址形成审计记录。

4.3.6 数据统计与系统日志模块

统计模块基于 MySQL 业务记录提供检测概览、时间趋势、风险等级分布、类别分布、关键词统计、用户活跃度、知识库概览和向量同步状态分布。前端使用 ECharts 呈现这些聚合结果，统计接口只返回图表所需数据，不在后端生成截图。

系统日志模块记录关键管理行为，支持按动作、模块、用户和时间等条件分页查询。统计反映系统业务数据的总体状态，日志提供具体操作轨迹，两者共同服务于管理复核和问题定位，但不替代应用运行日志和外部服务监控。

4.4 新闻可信度评估流程设计

新闻可信度评估主流程如图 4-4 所示。该流程把检索增强生成（Retrieval-Augmented Generation, RAG）的知识准备、检索和生成环节[10]落实为可验证的候选证据管线，并针对大语言模型幻觉风险[12]增加证据契约、服务端质量重算和确定性降级。




图 4-4 新闻可信度评估总体流程图

4.4.1 新闻输入与文本规范化处理

用户可以手工输入新闻，也可以先调用提取预览接口处理 URL。URL 抓取只允许 HTTP 和 HTTPS 协议，默认拒绝指向本机、私有地址、链路本地地址及其他保留地址的目标；重定向由服务手动跟随，并在每一跳重新进行主机解析与地址检查，以降低服务端请求伪造风险。抓取设置超时时间，解析后返回标题、正文、发布时间和最终来源地址。用户可在检测页修改提取内容，再提交正式评估。

正式检测入口对标题和正文执行统一清洗，标题截取到 255 字符，正文截取到 12000 字符，任一为空则拒绝进入后续流程。清洗后的标题和正文用于关键词提取、RAG 查询和

模型分析；来源、发布时间和 URL 作为辅助元数据保存。该入口同时应用滑动窗口限流，游客以请求来源标识、登录用户以身份信息参与限流键构造，减少网页抓取和模型调用被高频滥用的风险。

4.4.2 本地知识库证据召回

本地召回先把标题和正文拼接为查询文本，并限制查询文本长度。DashScope Embedding 把查询转换为 1024 维向量，Chroma 在 knowledge_items 集合中按余弦距离检索 Top-10 候选。检索结果包含向量 ID、文档、元数据和距离，服务端按“1-距离”转换为相似度，并根据元数据中的 knowledge_id 回查 MySQL。

回查过程会跳过数据库中已不存在的条目，并以 MySQL 当前值覆盖标题、摘要、类别、真伪标签、来源、风险等级和同步状态。由此，Chroma 负责快速发现语义邻近项，MySQL 负责确认条目仍然有效。该二次校验增加了一次关系库查询，但避免索引残留直接污染证据池。

4.4.3 证据不足判定与联网补充

本地检索与联网补充流程如图 4-5 所示。




图 4-5 本地检索与联网补充流程图

联网搜索必须同时满足系统全局开关允许和用户在本次请求中启用。满足前提后，出现以下任一情况即触发补充：本地没有证据；Top-1 相似度低于 0.45；或者 Top-1 相似度低于 0.60 且相似度不低于 0.30 的“有效候选”少于 3 条。第一条规则处理知识库完全未覆盖的新闻，第二条处理最高命中仍明显偏弱的情况，第三条处理只有少量中等相关候选、证据面不足的情况。

博查搜索查询由标题和已提取关键词组成，结果数量和时效范围由环境配置控制。服务异常、超时或无结果时，检测流程保留本地候选继续执行，不把联网能力作为强制依赖。web_triggered 和网络证据数量等信息随分析载荷保存，便于区分“未触发搜索”和“触发后未得到可用证据”。

4.4.4 多源候选证据整理

本地候选和网络候选首先映射为统一证据结构，保留标题、摘要或片段、来源名称、来源 URL、发布时间、来源类型和相似度等字段。合并时本地最多保留 5 条，网络最多保留 5 条；同一来源内部按稳定标识进行去重，不对不同来源的相似标题做强制跨源合并，以免把独立报道错误折叠为同一条证据。

每条候选随后获得稳定 `candidate_id`：知识库证据使用 `kb:<knowledge_id>` 形式，网络证据使用 `web:<序号>` 形式。系统以新闻标题和正文构造种子，通过 SHA-256 得到可复现的来源中立顺序，再截取不超过 10 条候选送入模型。该设计避免始终把知识库或网络证据排在前面造成位置偏差，也使相同输入下的候选顺序可重现。原始候选列表仍被保存，模型输入上限不会导致审计信息丢失。

4.4.5 大语言模型证据分析与仲裁

DeepSeek 接收新闻文本、统一候选证据和当前默认 Prompt 模板，输出新闻可信度分量、理由、风险点、关键词、建议、证据质量和证据仲裁。仲裁的 `ranked` 项必须包含 `candidate_id`、相关性分、质量分、立场和理由；立场限定为 `support`、`contradict` 或 `neutral`。`rejected` 项包含 `candidate_id` 和排除原因。服务端要求 `ranked` 与 `rejected` 共同构成候选 ID 的完整、不重复划分，并检查分值、枚举和字段类型。

如果首次输出缺少仲裁对象、候选 ID 不完整、存在重复或证据质量字段无效，系统发起一次只聚焦证据仲裁的重试。重试通过后采用新的仲裁和质量数据；仍未通过时把状态标记为 `retry_exhausted`，不让未完成仲裁的候选影响评分。证据质量包含覆盖度 `C`、一致性 `K` 和说明，服务端不信任模型直接给出的总分，而是按 $0.6C + 0.4K$ 重新计算证据质量分。该机制把生成式输出转化为可验证的数据契约，是本系统可解释评估链路的核心设计。

4.4.6 可信度评分与风险等级判定

评分与风险分级流程如图 4-6 所示。




图 4-6 可信度评分与风险分级流程图

设大语言模型可信度分为 S_L ，确定性规则分为 S_R ，证据质量分为 S_E ，三者范围均规范到 0~100。 S_E 由证据覆盖度 C 与一致性 K 按式 (4-1) 计算：

$$S_E = 0.6C + 0.4K \quad (4-1)$$

当前主流程采用分支式综合评分，而不是对所有请求套用固定权重。若模型服务失败，由于检索候选尚未获得可信仲裁，最终分仅取规则分，如式 (4-2) 所示：

$$S = S_R \quad (4-2)$$

若模型可用但没有有效证据，最终分由模型分和规则分组成，如式 (4-3) 所示：

$$S = 0.6S_L + 0.4S_R \quad (4-3)$$

若存在通过仲裁的有效证据，则使用式 (4-4)：

$$S = 0.5S_L + 0.3S_E + 0.2S_R \quad (4-4)$$

规则分以 100 分为基准，根据可解释规则扣分：标题或正文出现夸张词扣 15 分，缺少来源扣 20 分，情绪化词语扣 15 分，绝对化表达扣 15 分；在有效证据 Top-5 中发现相似度

不低于 0.70 且立场冲突的内容时扣 25 分，最低为 0 分。检索相似度均值仍计算并保存为 `evidence_score`，用于展示和诊断，但不进入当前综合公式，避免把语义相似直接等同于事实可信。

最终分 S 按统一阈值映射： $S \geq 80$ 为“可信新闻”， $60 \leq S < 80$ 为“存疑信息”， $40 \leq S < 60$ 为“疑似谣言”， $S < 40$ 为“高风险谣言”。高风险标识同时依据分值低于 40 或等级为高风险谣言确定。该阈值函数被检测结果、高风险列表和管理复核共同使用，避免不同模块各自判断产生等级漂移。

4.4.7 异常降级与评估结果保存

联网搜索异常时系统继续使用本地候选；模型初次返回不满足证据契约时聚焦重试一次；模型服务整体失败时只使用规则分，并在理由和风险点中标记模型服务异常。Chroma 操作会清理缓存的客户端和集合句柄后重试一次，但检索或写入仍失败时由服务抛出可识别异常，接口转换为统一错误响应。数据库写入失败时回滚当前会话，不返回伪成功结果。

评估成功后，`detection_records` 保存输入快照、`evidence_score`、`llm_score`、`rule_score`、`final_score`、风险等级、判断结果、理由、风险点、建议和高风险标识。`analysis_payload` 进一步保存候选证据、排除证据、相似新闻、证据质量、仲裁状态、质量状态、错误摘要、尝试次数、契约版本及本地/网络有效命中标识。`evidence_matches` 只保存最终有效证据，并以 `rank_order` 记录仲裁后的顺序。这样的持久化粒度既支持用户展示，也为管理员复核和算法迭代保留了上下文。

4.5 数据库设计

4.5.1 数据需求分析

系统数据可以分为身份权限数据、知识数据、评估过程数据、配置数据、报告文件索引、审计数据和采集运行数据。身份权限数据回答谁可以访问何种功能；知识数据为 RAG 提供可维护事实材料；评估数据记录输入、分量、结论和证据；Prompt 模板控制模型输出契约；报告表关联生成文件；系统日志记录管理行为；采集任务记录后台调度的数量和状态。

由于语义检索数据由知识条目派生，系统还需要保存向量 ID、同步状态和同步错误。此类字段不是业务内容本身，却是判断 MySQL 与 Chroma 是否一致的重要运维数据。数据设计因此同时考虑业务查询、级联删除、可空关系和跨存储补偿，而不只保存最终评分。

4.5.2 数据实体及关系设计

系统真实实体及关系如图 4-7 所示。

关系数据库实体联系图




图 4-7 数据库 ER 图

users 与 detection_records 存在两类一对多关系：用户可以创建多条检测记录，管理员也可以复核多条记录；user_id 和 reviewed_by 均允许为空，并在用户删除时置空，以保留业务历史。detection_records 与 evidence_matches 是一对多关系，删除检测记录时证据级联删除。evidence_matches 到 knowledge_items 的外键允许为空，知识条目删除后将 knowledge_id 置空，但证据标题、摘要、来源和相似度快照仍可保留。

detection_records 与 reports 是一对零或一关系，reports.detection_id 具有唯一约束，检测删除时报告记录级联删除。users 与 reports、prompt_templates、system_logs 均为一对多可空关系，用户删除时外键置空。crawl_tasks 记录调度执行结果，不与用户或知识条目建立强外键，避免单次采集统计因后续知识维护而失真。

4.5.3 关系数据库表结构设计

核心关系表如表 4-3 所示。表中仅列出决定实体职责和关系的关键字段，时间戳、一般描述字段和全部索引细节留待第 5 章结合模型实现说明。

表 4-3 核心数据表说明

表名	主键	关键外键/约束	关键业务字段	主要职责
users	id	username、email 唯一	password_hash、role、status	保存账号、角色和账户状态
knowledge_ite	i	无强外键	title、content、	保

表名	主 键	关键外键/约束	关键业务字段	主 要职责
ms	d		truth_label、source、 vector_id、 vector_sync_status	存知识 事实及 向量同 步状态 保
detection_recor ds	i d	user_id、reviewed_by→users， 可空	输入快照、三 类分量、final_score、 risk_level、 analysis_payload	存完整 评估结 果与复 核状态 保
evidence_matc hes	i d	detection_id→detection_recor ds； knowledge_id→knowledge_items， 可空	title、 summary、 source_name、 similarity_score、 rank_order	存参与 最终判 断的有 效证据 快照 管
prompt_templat es	i d	created_by→users，可空	name、type、 content、is_default、 status	理模型 提示模 板和默 认模板 关
reports	i d	detection_id 唯一； user_id 可 空	title、 html_path、pdf_path	联检测 记录与 生成文 件 保
system_logs	i d	user_id→users，可空	action、 module、description、 ip_address	存管理 操作审 计信息 保
crawl_tasks	i d	无强外键	job_name、 search_query、数量 统计、started_at、 finished_at、status	存定时 采集任 务执行 摘要

4.5.4 Chroma 集合与向量元数据设计

Chroma 集合名称为 knowledge_items，距离空间设置为 cosine。每条向量文档 ID 采用 knowledge:<item.id>，使向量可由关系库主键稳定定位。文档文本由 title、content、category、summary、keywords、truth_label 和 debunking_explanation 按字段标签拼接，长度由服务限制。正式配置使用 DashScope text-embedding-v4，向量维度为 1024。

Chroma 原生元数据只保存 knowledge_id、title、category、truth_label、source_name 和 risk_level，均为检索过滤或结果初步展示需要的轻量字段。vector_sync_status 不写入 Chroma 元数据，而保存在 MySQL；检索回查后才加入返回结果。该设计避免同步状态自身又成为需要双向同步的数据。向量查询返回 distance 后转换为 similarity_score，类别、真伪标签和风险等级可作为 where 过滤条件。

4.5.5 MySQL 与 Chroma 数据一致性设计

MySQL 与 Chroma 协同关系如图 4-8 所示。




图 4-8 MySQL 与 Chroma 协同关系图

新增知识条目时系统先提交 MySQL，再生成 Embedding 并写入 Chroma；向量同步失败时保留知识条目，将 vector_sync_status 标记为 failed 并记录错误，便于管理员单条重试。更新知识条目时，MySQL 修改暂不提交，服务先执行向量 upsert；向量失败则回滚关系库修改，成功后再统一提交，从而使内容与索引尽量同时切换。

删除采用“先删向量、再删 MySQL”。若向量删除失败，关系记录保留并标记失败；若向量已删除而 MySQL 删除失败，服务回滚数据库会话并尝试恢复原向量，再把状态标记为 `delete_failed`。管理接口还提供单条重新向量化与全量重建集合。Chroma 客户端或集合句柄异常时，服务清除缓存句柄并重试一次。

这些策略属于应用层顺序控制和补偿，不是 MySQL 与 Chroma 的分布式事务。极端情况下仍可能需要管理员依据 `vector_sync_status` 和 `vector_sync_error` 执行单条重试或全量重建。明确这一边界比笼统宣称“强一致”更符合当前实现，也为后续引入异步补偿队列或软删除机制保留了演进方向。

4.6 接口与权限体系设计

4.6.1 接口设计原则

系统接口按业务资源分组，统一使用“/api”前缀。列表接口采用 `page`、`page_size` 和业务筛选参数，详情接口使用资源 ID，修改类接口使用明确的 POST、PUT、PATCH 或 DELETE 语义。请求体由 Pydantic 模型校验，返回体以 `code`、`message` 和 `data` 封装；文件下载接口根据资源权限返回实际文件响应。接口层只组织 HTTP 语义，评分和同步逻辑放在 Service 层，避免相同规则在用户接口和管理员接口重复实现。

公开、登录和管理员接口在路由层明确区分。检测与 URL 提取预览允许可选登录，高风险公开列表与系统健康检查不要求令牌；历史、详情、重新评估、RAG 搜索和报告生成要求登录；所有 /admin 接口要求管理员。采集任务目前由调度器根据配置执行，没有对外 REST 接口，本章不将 `crawl_tasks` 误列为可人工调用的接口资源。

4.6.2 系统接口分类

系统主要接口分类如表 4-4 所示。

表 4-4 系统接口分类表

接口类别	典型前缀/资源	访问要求	主要职责
认证接口	/auth	注册、登录公开； /me 需登录	注册、登录、获取当前用户
新闻检测接口	/detect	新闻检测和提取 预览可选登录；历史、 详情、重评需登录	提交评估、URL 预览、历史与详情
RAG 检索接口	/rag	登录	独立查询知识库 相似条目
报告接口	/report	登录且校验记录 归属	生成和下载检测 报告

接口类别	典型前缀/资源	访问要求	主要职责
高风险公开接口	/high-risk	公开	已公开高风险列表、排行、关键词和分类
管理业务接口	/admin/users、 /admin/detections、 /admin/high-risk	管理员	用户、检测和高风险复核管理
知识与 Prompt 接口	/admin/knowledge、 /admin/prompts	管理员	知识维护、向量恢复和模板管理
统计、报告与日志接口	/admin/statistics、 /admin/reports、 /admin/logs	管理员	统计聚合、报告查看和日志审计
健康检查接口	/health	公开	返回服务运行状态和版本信息

4.6.3 身份认证设计

用户登录时，服务端以 bcrypt 验证明文密码与 password_hash，校验账户为 active 后生成 JWT。令牌至少包含 sub 和 exp，并附带 role 及用户名信息；签名密钥、算法和过期分钟数来自环境配置。受保护接口通过 OAuth2PasswordBearer 读取 Authorization 头，解码令牌后仍按 sub 查询数据库用户，以确认用户存在且未被禁用。

可选身份依赖在请求没有 Authorization 头时返回空用户；如果请求主动携带了格式错误、无效或已禁用用户的令牌，则返回 401，而不是静默降级为游客。这一规则避免登录状态异常时产生归属不清的检测记录。前端会话恢复成功后才把用户视为已验证，路由守卫据此决定登录页、个人页和管理页跳转。

4.6.4 角色权限控制设计

系统角色与功能权限见表 4-1。权限矩阵不仅区分页面入口，还对应后端依赖和资源归属校验。

前端对 /admin 父路由及其子路由同时设置 requiresAuth 和 requiresAdmin，后端所有管理路由再次依赖 get_current_admin。公开高风险页面只展示 is_public 条件下的数据，审核状态、管理员备注和未公开记录留在管理接口。游客结果页可承接当次检测返回的数据，但需要持久化历史、详情或报告能力时必须登录，这一访问边界与后端接口保持一致。

4.6.5 统一响应与异常处理设计

普通 JSON 成功响应为 {code, message, data}，其中 code 与预期 HTTP 语义一致。HTTPException 由全局处理器保留状态码并转换 detail；Pydantic 请求校验异常统一返回 422，并把字段位置和错误信息拼接为可读消息；SQLAlchemy 异常返回 500 和数据库配置或操作

提示。服务层可识别异常在 API 层映射为 400、404、409、422 或 503 等状态，避免所有错误都返回 200。

前端响应拦截器可依据 HTTP 状态和统一 message 给出提示，并在 401 时清理失效会话。统一外层结构不意味着抹平错误类型：模型服务异常、向量同步异常、资源不存在、权限不足和参数错误仍通过状态码及消息区分。报告下载属于二进制响应，不强行套用 JSON 结构。

4.7 系统安全性与可靠性设计

系统安全性与可靠性措施如表 4-5 所示。

表 4-5 系统安全性与可靠性设计表

设计对象	已实现措施	主要作用与边界
身份与密码	JWT、bcrypt、账户状态复查、管理员依赖	限制受保护资源访问；令牌安全仍依赖密钥保管和 HTTPS 部署
输入与接口	Pydantic 校验、文本清洗、长度限制、滑动窗口限流、CORS 配置	降低非法参数和高频调用风险；当前限流为进程内实现
数据访问	SQLAlchemy 参数化查询、会话回滚、外键与唯一约束	降低注入与部分写入风险；需配合最小数据库权限
URL 抓取	仅 HTTP/HTTPS、私有/保留地址阻断、逐跳重定向校验、超时	降低 SSRF 和长时间占用风险；不能替代网络层出口控制
外部智能服务	API 密钥环境变量、超时、结构校验、仲裁重试和降级	减少外部失败扩散；模型结论仍需人工复核
双存储一致性	同步状态、错误记录、回滚、向量恢复、单条/全量重建	提供异常恢复路径；不是分布式强一致事务
审计与文件	管理操作日志、配置化报告目录、数据库保存文件索引	支持追踪与文件定位；目录权限由部署环境保证

4.7.1 用户输入与接口访问安全

账号、分页、枚举和检测请求由 Schema 层进行类型与范围校验，文本进入业务前使用统一清洗函数处理。SQLAlchemy 通过表达式和绑定参数访问数据库，业务代码不拼接用户输入生成 SQL。注册、登录、新闻检测和 URL 预览使用进程内滑动窗口限流器，配置项控制时间窗口和请求数量。该实现适合当前单实例部署；若扩展为多进程或多节点，需要迁移到共享限流存储才能获得全局一致配额。

CORS 允许来源由环境变量控制。当允许来源不是通配符时才开启凭据支持，避免通配来源与凭据组合。管理接口要求管理员角色，普通用户接口还会检查记录归属。系统不声称完全消除越权风险，但通过前端导航限制、后端依赖校验和资源级归属检查形成多层访问边界。

4.7.2 外部服务调用与敏感配置安全

数据库密码、JWT 密钥、DeepSeek 密钥、DashScope 密钥和博查密钥均从 `.env` 读取，`.env.example` 只提供配置项说明。代码和论文不保存真实凭据。外部调用设置超时并捕获 HTTP、网络和 JSON 解析异常；URL 抓取在解析初始地址和每次重定向时检查目标地址，减少由恶意 URL 访问内部网络的可能性。

模型响应需经过 JSON 提取、字段清洗、分值归一化和证据契约校验。即使模型返回了 `evidence_quality.score`，服务端仍使用覆盖度与一致性重算；即使候选相似度较高，未完成仲裁也不进入评分。这些措施不能证明模型输出必然正确，但可以限制非结构化输出直接改变业务状态的范围。

4.7.3 数据一致性与故障降级设计

MySQL 写操作使用会话提交和回滚，检测记录与有效证据在同一业务过程内保存。知识更新把数据库提交推迟到 Chroma upsert 成功之后；删除失败时尝试恢复向量并记录 `delete_failed`。向量同步状态为 `pending`、`synced`、`failed` 或 `delete_failed`，管理员可据此执行单条向量化或全量重建。

联网搜索是可选增强，失败时不影响本地证据路径；模型失败时使用规则分而不伪造证据质量；报告生成失败不改变检测记录。上述降级策略优先保证已确定数据不被外部故障破坏，同时在结果中暴露能力缺失。对于 Chroma 完全不可用或数据库不可用等核心依赖故障，系统返回明确错误而不是生成无依据结论。

4.7.4 系统日志与操作审计设计

`system_logs` 保存操作者、动作、模块、描述、IP 地址和时间。知识条目维护、Prompt 变更、用户启停、高风险复核、报告和检测记录管理等操作可形成审计轨迹。管理员日志页支持筛选和分页，便于定位谁在何时修改了关键配置或业务数据。

检测过程自身的可追溯信息主要保存在 `detection_records.analysis_payload`，而不是全部写入 `system_logs`。前者记录算法上下文，后者记录管理行为，两者职责分离。应用运行日志仍由 Python 日志系统输出，用于记录外部服务异常、重试和补偿失败；生产环境可在此基础上接入集中日志平台，但当前项目未实现独立监控告警系统。

4.8 用户界面与交互设计

4.8.1 用户端界面结构设计

用户端真实页面结构如图 4-9 所示。




图 4-9 用户端页面结构图


UserLayout 提供公共导航和内容出口。首页、新闻检测、检测结果和高风险新闻为公开路由；登录和注册为 `guestOnly` 路由，已验证登录用户访问时会被重定向；历史记录和个人中心要求登录。新闻检测页同时提供文本输入和 URL 提取预览，用户可以控制是否允许联网搜索。结果页以评分卡、风险标签、判断理由、风险点、建议和证据列表组织信息，避免只呈现单一真假标签。

页面交互统一考虑加载、空数据和失败状态。检测期间显示步骤与加载反馈，防止用户重复提交；历史和高风险页面使用筛选与分页；证据列表按有效与排除语义组织；登录用

户可从结果或历史进入报告生成。公开结果页只承担当次结果呈现，个人历史与持久化详情仍由登录权限保护。

4.8.2 管理员端界面结构设计

管理员端真实页面结构如图 4-10 所示。



AdminLayout 下包含后台首页、用户管理、检测记录、知识库、Prompt 模板、高风险管理、数据统计、报告管理和系统日志九个页面。后台首页与统计页负责概览和图表，核心业务页以筛选、表格、分页、详情和确认对话框为主，知识库页额外提供单条向量化和全量索引重建，高风险页提供复核、公开状态和管理员备注操作。

当前 Vue Router 中没有采集任务页面，因此图 4-10 不包含“采集任务管理”。采集状态只保存在 crawl_tasks 并由后台调度器写入。这样的如实划界能够避免论文界面设计与实际可访问页面不一致，也说明采集能力当前属于系统内部维护机制而非管理员交互功能。

4.8.3 核心业务交互流程设计

核心交互从新闻输入开始。手工模式下，用户填写标题、正文和可选来源；URL 模式下，用户先请求提取预览，核对后再提交。前端在请求期间展示加载状态，成功后跳转结果

页；失败时保留用户输入并展示后端 `message`。结果页优先呈现最终分和风险等级，其后是判断理由、风险点、建议、有效证据和相似新闻，使用户先获得结论，再逐层查看依据。

登录用户可以从历史列表进入详情，或使用原输入重新评估。报告生成由用户主动触发，成功后提供下载入口。管理员在后台通过筛选定位记录或知识条目，危险操作使用确认交互；高风险记录可以先复核再决定是否公开；统计页把趋势、分布和关键词数据转换为图表。整个交互设计围绕“输入可修订、过程有反馈、结论有证据、管理可追踪”展开，并与后端权限和数据状态保持一致。

4.9 本章小结

本章依据项目真实实现完成了系统总体设计。系统以 `Vue 3` 与 `FastAPI` 构成前后端分离架构，以 `MySQL` 保存业务事实、`Chroma` 维护知识语义索引，并通过 `DeepSeek`、`DashScope`、博查搜索和新闻网页提取形成多源智能处理链路。功能上覆盖认证、新闻评估、记录与报告、知识与采集、管理治理、统计与审计六个模块。

新闻评估流程采用本地 `Top-10` 召回、条件式联网补充、候选证据稳定标识、来源中立排序、逐条证据仲裁、服务端证据质量重算和分支式综合评分。`MySQL` 与 `Chroma` 通过同步状态、回滚、恢复和索引重建降低不一致风险，并明确其应用层补偿边界。接口、权限、安全和界面设计均与当前路由、模型和服务保持一致，为第 5 章的详细设计与实现提供了结构化依据。

第 5 章 系统详细设计与实现

本章在前四章需求、技术选型和总体架构的基础上，对智闻辨真系统的核心实现进行说明。撰写过程以当前项目代码、配置、数据库模型、迁移、接口、测试和真实运行页面为事实来源，重点描述新闻输入、RAG 证据检索、联网补充、候选证据组织、大语言模型证据仲裁、分支式评分、持久化以及异常降级之间的完整调用链。

需要说明的是，本章讨论的是系统功能和工程实现是否落地，不给出准确率、召回率、F1 值、压力测试或模型对比结论；这些内容属于后续系统测试与实验分析章节。

5.1 系统实现概述

5.1.1 项目代码组织

后端采用 FastAPI、SQLAlchemy、Alembic 和服务层编排结构，前端采用 Vue3、Pinia、Vue Router、Element Plus 和 Axios。与第五章实现直接相关的目录如下：

代码 5-1 项目主要目录职责

backend/app/	
├─ api/	接口路由、权限依赖和后台接口
├─ models/	MySQL ORM 模型
├─ schemas/	Pydantic 请求、响应和契约结构
├─ crud/	数据访问与持久化封装
├─ services/	检测、RAG、LLM、报告和外部服务编排
├─ core/	配置、安全、JWT、依赖注入和限流
└─ templates/	PDF 报告 HTML 模板
frontend/src/	
├─ api/	前端接口封装
├─ views/	检测、结果、历史、后台等页面
├─ components/	证据、评分、状态等复用组件
├─ stores/	登录用户和全局状态
└─ router/	页面路由与权限守卫

5.1.2 核心业务调用链

新闻可信度评估入口位于前端 DetectView 页面和后端`POST /api/detect/news`接口。接口进入`detect\_news\_credibility`服务后，先完成文本清洗和关键词抽取，再调用知识库语义

检索；当本地证据不足且用户允许联网时调用 Bocha 搜索进行补充。候选证据统一后交给 DeepSeek 兼容接口生成结构化判断，服务端再执行证据仲裁契约校验、证据质量重算、规则评分和分支式综合评分，最后将检测记录、有效证据和分析过程数据写入 MySQL。图 5-1 展示了该调用链。



图 5-1 新闻可信度评估核心实现调用链

5.1.3 设计与实现映射

第 4 章给出了总体架构和方法流程，第 5 章将其落到具体模块、数据表和页面状态上。表 5-1 列出核心设计点和实现载体。

表 5-1 设计与实现映射

第 4 章设计内容	第 5 章实现位置	主要实现载体	关键状态或数据
URL 提取	5.3	WebContentFetcherExtr actPreviewRequest、 DetectView	title、content、source_url、 publish_time_precision
本地语义检索	5.4	knowledge_service、 chroma_service	knowledge_id、 similarity_score、Top-10
联网证据补充	5.5	web_search_service、 BochaClient	web_search_enabled、web 候选、source_type
候选证据组织	5.5	merge_evidence、 _ensure_candidate_ids	candidate_id、source_type、 rank_order
模型证据仲裁	5.6	llm_service、 validate_and_apply_llm _ranking	ranked_evidence、 rejected_evidence
契约校验	5.6	detection_service	arbitration_status 、

			quality_status 、
			analysis_contract_version
分支评分	5.7	detection_service、	S_L 、 S_E 、 S_R 、
		rule_score_service	final_score
结果持久化	5.8	DetectionRecord、	analysis_payload 、
		EvidenceMatch	risk_level、 review_status
跨存储恢复	5.9	knowledge_service	vector_sync_status 、
			vector_sync_error
		AdminKnowledgeView	
报告生成	5.10	report_service 、	pdf_path、 report_url、
		Report 模 型 、	download_url
		ResultView	

5.2 用户认证与权限控制实现

5.2.1 用户注册与密码安全

注册接口位于`api/v1/auth.py`，请求进入服务层前由 Pydantic 校验用户名、邮箱和密码字段。`AuthService.register`会分别检查用户名和邮箱是否已存在，重复时返回明确错误；创建用户时将密码交给`passlib`的`bcrypt`上下文生成哈希值，数据库只保存`password\_hash`，不会保存明文密码。注册和登录接口还通过内存限流器限制同一 IP 在窗口期内的频繁请求。

5.2.2 登录认证与 JWT 令牌

登录时服务端根据用户名查找用户、校验`bcrypt`哈希并确认账号状态为`active`，随后使用`create\_access\_token`生成包含`sub`、`exp`和角色信息的 JWT。前端登录成功后将令牌保存到`localStorage`，Axios 请求拦截器自动写入`Authorization: Bearer`头；后端`get\_current\_user`依赖负责解析令牌、查库加载用户并处理过期、伪造或用户不存在等情况。

5.2.3 角色权限与资源归属校验

系统区分普通用户、管理员和游客。游客可提交检测或 URL 预览，但不能查询历史和下载报告；普通用户只能读取本人检测记录；管理员可进入后台知识库、Prompt、高风险复核、统计和日志页面。历史记录、检测详情和报告下载均进行资源归属校验，其中报告下载还会校验 PDF 路径必须位于配置的报告根目录内。

代码 5-2 当前用户加载与管理员权限依赖

```

def get_current_user(token: str = Depends(oauth2_scheme), db: Session =
Depends(get_db)):
    payload = decode_token(token)
    user_id = payload.get("sub") if payload else None
    if not user_id:
        raise HTTPException(status_code=401, detail="invalid token")
    user = db.query(User).filter(User.id == int(user_id)).first()
    if user is None or user.status != "active":
        raise HTTPException(status_code=401, detail="inactive or missing
user")
    return user

def get_current_admin(current_user: User = Depends(get_current_user)):
    if current_user.role != "admin":
        raise HTTPException(status_code=403, detail="admin required")
    return current_user

```

5.3 新闻输入与网页内容提取实现

5.3.1 手工新闻输入与参数校验

手工检测请求由`DetectNewsRequest`承载。标题最长 255 字符，业务校验要求清洗后不少于 4 个字符；正文至少 20 个字符，后端进入服务层后将正文清洗并限制到 12000 字符，前端表单同时以 5000 字符作为输入提示上限。类别、来源名称、来源 URL、发布时间和是否启用联网搜索为可选字段，空字符串会被转换为`None`，避免将无效空值写入数据库。

Pydantic 负责字段类型、长度和空白文本校验，`detect\_news\_credibility`负责语义层的文本清洗、关键词抽取和后续检测编排。前端 DetectView 通过 Element Plus 表单规则给出即时提示，后端错误则通过统一响应中的`message`显示在页面。

5.3.2 新闻 URL 内容提取

URL 提取采用“预览—确认—检测”两阶段。用户在 DetectView 粘贴链接后，前端调用`POST /api/detect/extract-preview`；后端只抓取网页并返回标题、正文、来源、URL 和发布时间，不创建检测记录。用户可以在页面回填结果基础上继续修改，确认后再提交`/api/detect/news`进入完整检测链路。真实运行时的 URL 提取回填状态见图 5-7。

5.3.3 发布时间与来源信息规范化

网页解析服务会优先从 Open Graph、Twitter Card、JSON-LD、`time` 标签和正文附近的时间表达中提取发布时间，并区分`date`与`datetime`两种精度。响应模型要求日期格式为`YYYY-MM-DD`，日期时间格式可由`datetime.fromisoformat`解析；无法识别时返回空值并允许用户手工填写。来源名称默认取网页元信息或最终 URL 主机名，`source\_url`使用安全校验后的最终访问地址。

5.3.4 SSRF 防护与请求限制

URL 抓取属于直接访问外部地址的高风险入口，因此`WebContentFetcher`先执行协议白名单和主机校验，再进行 DNS 解析。实现拒绝本机、私有、链路本地和保留网段地址；每次重定向后都会重新校验目标主机，最多允许 3 次重定向。HTTP 请求超时为 10 秒，读取体上限为 2MB，内容类型限定为 HTML、XHTML 或纯文本。异常统一返回 422，不写入检测记录。图 5-2 给出了时序。




图 5-2 新闻 URL 提取与安全校验时序图

代码 5-3 URL 协议、地址和重定向安全校验

```

ALLOWED_SCHEMES = {"http", "https"}

FETCH_TIMEOUT = 10.0

MAX_FETCH_BYTES = 2 * 1024 * 1024

MAX_REDIRECTS = 3

```

```

def _normalise_url(url):

    parsed = urlparse(url.strip())

    if parsed.scheme not in ALLOWED_SCHEMES or not parsed.hostname:

        raise SSRFBlockedError("unsupported or missing host")

    return urlunparse(parsed._replace(fragment=""))

for hop in range(MAX_REDIRECTS + 1):

    self._assert_safe_url(current_url)

    response = opener.open(current_url, timeout=self._timeout)

    if response.status in REDIRECT_STATUS:

        current_url = urljoin(current_url, response.headers["Location"])

        continue

```

5.4 新闻知识库与本地语义检索实现

5.4.1 知识文本组织与向量化

知识条目由`KnowledgeItem`模型保存，Embedding 文本不是单独使用正文，而是将标题、正文、类别、摘要、关键词、真实性标签和辟谣说明按标签拼接，最大长度限制为 8000 字符。当前配置使用 DashScope 兼容接口，模型为`text-embedding-v4`，维度为 1024；项目也保留`hash` provider 作为本地演示兜底，但正式 RAG 检索以 DashScope 语义向量为准。

5.4.2 Chroma 向量写入与 Top-K 检索

Chroma 集合名为`knowledge\_items`，元数据指定`hnsw:space=cosine`。知识向量 ID 采用`knowledge:<id>`，向量元数据包含知识库 ID、标题、类别、真实性标签、来源和风险等级。检测时查询文本由新闻标题和正文构成，`RAG\_TOP\_K=10`，Chroma 返回距离后由服务端转换为`max(0,1-distance)`形式的相似度。图 5-3 展示了本地检索和业务回查过程。



图 5-3 本地语义检索与业务数据回查流程

5.4.3 检索结果业务数据回查

向量库只作为召回索引，不作为业务事实源。`search\_similar\_knowledge`从 Chroma 结果的 metadata 读取`knowledge\_id`后回查 MySQL；若数据库记录不存在则跳过该向量，若存在则使用 MySQL 中的当前标题、摘要、分类、真实性标签、来源和同步状态覆盖向量库元数据。这样可以避免旧向量元数据直接进入业务响应。

代码 5-4 向量检索与 MySQL 回查核心逻辑

```
vector_results = search_knowledge_vectors(query_text, top_k=top_k)

items = []

for result in vector_results:

    metadata = result.get("metadata") or {}

    knowledge_id = int(metadata.get("knowledge_id") or 0)

    item = db.query(KnowledgeItem).filter(KnowledgeItem.id == knowledge_id).first()

    if item is None:

        continue

    result["knowledge_id"] = item.id

    result["title"] = item.title

    result["summary"] = item.summary

    result["truth_label"] = item.truth_label

    result["vector_sync_status"] = item.vector_sync_status

    items.append(result)
```

5.4.4 向量同步状态与索引重建

知识库表包含`vector\_sync\_status`和`vector\_sync\_error`字段，取值包括`synced`、`pending`、`failed`和`delete\_failed`。管理员后台展示同步状态，并提供单条重新向量化和全量重建入口。模型或维度变更后，应通过全量重建重置 Chroma 集合并逐条同步 MySQL 知识条目。真实后台中演示知识条目的`synced`状态见图 5-12。

5.5 多源候选证据获取与组织实现

5.5.1 联网补充的动态触发

系统不会无条件联网。`should\_trigger\_web\_search`首先要求用户请求中的`enable\_web\_search=True`且系统配置`WEB\_SEARCH\_ENABLED=true`。随后根据本地 RAG

结果判断：本地无候选时触发；Top-1 相似度低于 0.45 时触发；Top-1 低于 0.60 且相似度不
低于 0.30 的有效候选少于 3 条时触发。上述阈值是当前初始工程配置，用于召回补充判断，
不表示经过实验优化的最优参数。

5.5.2 网络搜索结果标准化

联网搜索由`BochaClient`调用 Bocha Web Search 接口，最大重试 2 次；认证失败和限
流不重试，超时、5xx 和网络异常按指数退避重试。搜索结果会被转换为与本地证据兼容的
结构，包括标题、摘要、来源站点、URL、发布时间、相似度、`source\_type=web\_search`
和`source\_label=网络检索`，使后续候选组织和 Prompt 构造可以统一处理。

5.5.3 候选证据去重与稳定标识

本地证据优先按`knowledge\_id`去重，网络证据优先按规范化 URL 去重；缺少 URL 时，
使用标题、来源和发布时间组成的键去重。合并时本地候选最多保留 5 条、网络候选最多保
留 5 条，Prompt 输入最多 10 条。候选标识方面，本地知识条目使用`kb:<knowledge\_id>`，
缺少知识 ID 的本地召回使用`kb:rag:<序号>`，网络候选使用`web:<序号>`，冲突时追加后缀。

表 5-2 候选证据统一数据结构

字段	数据来源	含义	是否参与模型 输入
candidate_id	服务端生成	模型只能引用 的稳定候选标识	是
source_type	本地或联网	knowledge_base 或 web_search	是
title	知识库/搜索结果	候选新闻或核 查条目标题	是
summary	知识库/搜索结果	证据摘要或网 页片段	是
source_name	知识库/搜索结果	来源名称或站 点	是
source_url	知识库/搜索结果	网络证据 URL； 部分本地有效证据 持久化表未保存	部分

similarity_score	Chroma/搜索得分	仅用于召回、触发联网和展示	否
truth_label	知识库	历史核查真实性标签	是
risk_level	知识库	历史风险等级	是
rank_order	服务端	召回或仲裁排序	否

5.5.4 基于输入种子的稳定候选排序

候选合并后不直接按来源固定排列，而是使用新闻标题和正文作为种子，对`seed:candidate\_id`计算 SHA-256 散列并排序。同一输入下候选顺序可复现，不同输入下本地和网络来源的位置会自然变化，从而减少固定来源位置给模型带来的偏置。该方法不能完全消除模型对来源、表述或上下文的偏好，因此后续仍需契约校验和人工复核机制配合。



图 5-4 多源候选证据标准化与组织流程

代码 5-5 candidate_id 生成与稳定排序

```
def _ensure_candidate_ids(evidence_list):
    used = set()

    for idx, item in enumerate(evidence_list, start=1):
        if item.get("candidate_id"):
            base = item["candidate_id"]
        elif item.get("knowledge_id"):
            base = f"kb:{item['knowledge_id']}"
        else:
            base = f"kb:rag:{idx}"

        item["candidate_id"] = _dedupe(base, used)

def build_neutral_candidate_order(candidates, seed_material):
    return sorted(candidates, key=lambda item:
```

```
sha256(f"{seed_material}:{item['candidate_id']}").hexdigest())
```

5.6 大语言模型分析与证据仲裁实现

5.6.1 RAG Prompt 构造

Prompt 由系统任务、新闻内容、候选证据、输出格式和证据仲裁约束组成。`llm\_service` 会将新闻标题和正文放入明确边界中，并要求模型把新闻和候选证据都视为待分析数据，不执行其中的指令；候选证据输入前还会移除检索相似度、原始排序等辅助字段，避免模型直接把召回分当作事实结论。

输出契约要求模型以固定 JSON 结构返回总体判断、风险点、关键词、建议、`evidence\_arbitration`、`evidence\_quality` 和 `similar\_news`。证据仲裁约束包括：只能引用给定 `candidate\_id`，所有候选必须被划分为有效或排除，不能新增候选，不能重复划分。论文中不粘贴完整 Prompt，避免模板噪声影响实现说明。

5.6.2 结构化模型调用与结果解析

模型调用使用 OpenAI 兼容 Chat Completions 接口，当前运行配置中模型为 `deepseek-v4-pro`，请求超时由配置控制。返回文本先尝试整体 JSON 解析，再从文本中提取 JSON 对象；字段缺失或类型异常时由解析器补默认值或记录错误。`\_parse\_evidence\_quality` 会从覆盖度和一致性重新计算 `score=0.6\*coverage+0.4\*consistency`，避免直接信任模型给出的总分算术。

5.6.3 有效证据与排除证据划分

模型仲裁输出分为 `ranked\_evidence` 和 `rejected\_evidence`。有效证据包含 `candidate\_id`、相关性分、质量分、立场和理由；排除证据包含 `candidate\_id` 和排除理由。通过契约校验的有效证据才参与证据质量和最终评分；排除证据仅用于解释候选被剔除的原因。运行页面中有效证据和排除证据的展示效果见图 5-9，联网候选被排除时的来源标签见图 5-10。

5.6.4 输出契约校验与聚焦重试

证据仲裁契约校验在服务端完成，它验证的是结构、范围和候选完整性，不能单独证明模型语义判断的事实正确性。首次校验失败时，系统最多进行一次聚焦重试，重试 Prompt 只要求修复证据仲裁、证据质量和相似新闻结构；若仍失败，则该批候选不参与证据质量和最终评分，并在 `analysis\_payload` 中保存异常摘要。

表 5-3 证据仲裁输出契约校验规则

校验项	合法要求	异常处理
candidate_id 合法性	必须来自本次候选集	记录错误并触发聚焦
	合	重试
候选完整覆盖	每个候选必须出现在有效或排除列表之一	重试；仍失败则不使用仲裁结果
不重复划分	同一 candidate_id 不能重复或跨列表出现	重试并记录重复 ID
分数范围	相关性和质量分为 0 到 100 数字	重试；非法项不落入有效证据
立场枚举	support 、 contradict 、 neutral 之一	重试并记录枚举错误
必需字段	有效证据含分数、立场和理由；排除证据含理由	重试或标记 retry_exhausted
理由文本	非空字符串	缺失时视为契约失败




图 5-5 模型证据仲裁、契约校验与聚焦重试流程

代码 5-6 证据仲裁契约校验核心逻辑

```

ranked = arbitration.get("ranked_evidence")
rejected = arbitration.get("rejected_evidence")
candidate_ids = {c["candidate_id"] for c in candidates}
seen = set()
for item in ranked:
    cid = item.get("candidate_id")
    if cid not in candidate_ids or cid in seen:
        errors.append("invalid or duplicated candidate_id")

```

```

if item.get("stance") not in {"support", "contradict", "neutral"}:
    errors.append("invalid stance")

_check_score(item.get("relevance_score"))

_check_score(item.get("quality_score"))

seen.add(cid)

for item in rejected:

    cid = item.get("candidate_id")

    if cid not in candidate_ids or cid in seen:

        errors.append("invalid rejected candidate")

missing = candidate_ids - seen

```

5.7 可信度评分与风险分类实现

5.7.1 大语言模型语义分处理

模型语义分记为`S\_L`，来源于解析后的`llm\_score`字段。服务端将其归一化到 0 到 100 之间，缺失或非数字时按 0 处理。若`\_is\_llm\_failure`识别到模型整体失败，系统会构造降级结果并使最终评分仅依赖规则分。

5.7.2 证据质量分计算

证据质量分记为`S\_E`，由覆盖度`C`和一致性`K`计算。服务端重新计算总分而不是直接采用模型返回的证据质量总分，保证算术和范围一致；但这只能保证公式计算正确，不能证明模型给出的`C`和`K`绝对正确。

$$S_E=0.6C+0.4K \quad (5-1)$$

5.7.3 确定性规则评分

规则分`S\_R`由`rule\_score\_service`计算，初始为 100 分，并根据来源完整性、表达风险、证据冲突和事实可信度线索扣分。规则项不是直接判定新闻虚假，而是为综合评分提供可解释的风险信号。

表 5-4 确定性规则评分

规则项	触发条件	分值变化	反映的风险
来源完整性	缺少来源名称 且标题正文无官方 机构线索	-20	来源不可追溯

夸张表达	出现“震惊”“疯传”“必看”等传播型词语	-15	标题党或诱导传播
情绪化表达	出现强烈情绪词	-15	表述可能偏离中性新闻风格
绝对化表达	出现“百分百”“一定”“所有人”等绝对词	-15	过度承诺或泛化
证据冲突	有效证据 Top5 含不实、谣言等负向线索且相似度较高	-25	与历史核查证据冲突

5.7.4 分支式综合评分

综合评分根据模型可用性和有效证据是否存在分为三支。模型不可用时，系统只使用规则分，避免使用失效模型分；模型可用但没有有效证据时，使用语义分和规则分；存在有效证据时，引入证据质量分。

$$S=S_R, \text{ 模型服务不可用} \quad (5-2)$$

$$S=0.6S_L+0.4S_R, \text{ 模型可用但无有效证据} \quad (5-3)$$

$$S=0.5S_L+0.3S_E+0.2S_R, \text{ 模型可用且存在有效证据} \quad (5-4)$$

算法 5-1 新闻可信度分支式评分算法

输入: `S_L`、`S_R`、`evidence_quality`、`effective_evidence`、`llm_status`

如果 `llm_status == failure`:

`S = S_R`

否则如果 `effective_evidence` 为空:

`S = 0.6 * S_L + 0.4 * S_R`

否则:

`C = evidence_quality.coverage`

`K = evidence_quality.consistency`

`S_E = 0.6 * C + 0.4 * K`

$$S = 0.5 * S_L + 0.3 * S_E + 0.2 * S_R$$

$S = \text{clamp}(\text{round}(S, 2), 0, 100)$

返回 S 与风险等级

5.7.5 风险等级映射与降级状态

风险等级由最终分数映射：80 分及以上为可信新闻，60 到 79.99 分为存疑信息，40 到 59.99 分为疑似谣言，低于 40 分为高风险谣言。页面会区分正常评估、证据不足、模型降级和仲裁不完整状态。图 5-8 展示正常模型可用、证据质量可用时的总览；图 5-14 展示模型服务异常导致证据仲裁暂不可用时的降级状态。

5.8 检测结果持久化与查询实现

5.8.1 检测记录与证据保存

检测完成后，`save\_detection\_record` 创建 `DetectionRecord` 并关联 `EvidenceMatch`。记录保存新闻标题、正文、类别、关键词、最终分数、证据召回展示分、模型分、规则分、风险等级、判断结论、判断理由、风险点、建议、高风险标记和报告 URL。有效证据表保存 `knowledge\_id`、标题、摘要、来源名称、相似度和排序。当前 ORM 模型没有保存网络证据 URL 和来源类型到 `EvidenceMatch`，这些内容主要保留在 `analysis\_payload` 中。

5.8.2 评估过程数据持久化

`analysis\_payload` 以 JSON 字符串保存过程数据，包括发布时间、来源名称、来源 URL、是否允许联网、原始候选列表、排除证据、相似新闻、证据质量、仲裁状态、质量状态、仲裁错误、重试次数、契约版本、本地证据是否命中和网络证据是否命中等。这样详情页和后续复核可以还原模型仲裁和降级原因。

5.8.3 历史记录、详情与重新评估

登录用户可通过 `GET /api/detect/history` 查询本人历史记录，管理员可在后台按条件查看全量记录。`GET /api/detect/{id}` 会先按当前用户角色和资源归属过滤，再返回详情。重新评估接口不会覆盖原记录，而是基于原输入重新执行检索、模型和评分，生成新的检测记录，保留历史审计链路。历史记录与 PDF 报告状态见图 5-11。

5.8.4 高风险记录与复核状态

当最终分数低于 40 或风险等级为高风险谣言时，系统将 `is\_high\_risk` 置为真。高风险后台支持待审核、审核通过和驳回状态，并可控制是否公开。未审核或驳回记录不会进入用户端公开高风险列表。管理员复核列表见图 5-13。

5.9 知识库跨存储一致性与恢复实现

5.9.1 知识条目新增与向量同步

系统以 MySQL 中的 `KnowledgeItem` 作为业务事实源，Chroma 只作为派生索引。新增知识条目时，服务先提交 MySQL 记录，再调用 `\_sync\_knowledge\_vector` 生成 Embedding 并写入 Chroma；若向量生成或写入失败，知识条目仍保留，状态标记为 `failed` 并记录错误，供管理员后台重试。

5.9.2 知识条目修改与向量替换

修改知识条目时，服务在同一数据库会话中先更新 MySQL 对象并 flush，再调用 Chroma upsert 替换旧向量。若向量同步失败，服务抛出 `KnowledgeVectorSyncError` 并回滚本次数据库修改，避免业务字段已更新但向量仍对应旧文本。

5.9.3 知识条目删除与补偿处理

删除流程先删除 Chroma 向量，成功后再删除 MySQL 记录。若向量删除失败，系统不删除 MySQL 并标记同步失败；若向量删除成功但数据库删除失败，服务尝试恢复向量并将状态标记为 `delete\_failed`。该补偿降低跨存储不一致概率，但不能彻底消除进程硬崩溃、断电或强制终止形成的中间状态。

代码 5-7 知识库删除的跨存储补偿

```
item = get_knowledge_item(db, item_id)

try:
    delete_knowledge_vector(item)
except Exception as exc:
    mark_vector_failed(db, item, str(exc))
    raise KnowledgeVectorSyncError(str(exc))

try:
    db.delete(item)
    db.commit()
except Exception:
    db.rollback()

try:
    upsert_knowledge_item_vector(item, build_embedding_text(item))
except Exception as restore_exc:
```

```
mark_delete_failed(db, item_id, str(restore_exc))

raise
```

5.9.4 同步重试与全量索引重建

管理员可以对单条失败知识执行重新向量化，也可以触发全量索引重建。全量重建会重置 Chroma 集合，然后遍历 MySQL 知识条目逐条同步并统计成功、失败和失败 ID。当前实现以重置集合的方式消除孤立旧向量，不包含独立后台定时孤立向量扫描任务。图 5-6 总结跨存储同步、补偿和恢复流程。




图 5-6 MySQL 与 Chroma 跨存储同步、补偿和恢复实现流程

5.10 检测报告生成与文件管理实现

5.10.1 报告模板渲染

报告服务读取检测详情和有效证据，将标题、正文摘要、分数、风险等级、判断理由、风险点、建议、证据项、生成时间和用户信息组织为 Jinja2 模板上下文。模板文件位于`backend/app/templates/reports/detection\_report.html`，生成的 HTML 作为 PDF 转换输入。

5.10.2 PDF 文件生成

PDF 生成由`xhtml2pdf`完成。报告根目录来自`REPORT\_DIR`配置，当前配置位于后端源码目录之外的`../data/reports`。文件名使用`report\_{<uuid32>}.pdf`和对应 HTML 文件，按`detection\_{<id>`子目录保存，降低不同检测记录之间的文件冲突。

5.10.3 报告记录与文件一致性

PDF 转换成功后，`save\_generated\_report`创建或更新`Report`记录，并同步更新检测记录的`report\_url`。下载前，服务校验报告记录存在、当前用户拥有该检测记录或为管理员、PDF 路径位于报告根目录内、文件名符合生成规则且文件实际存在。

5.10.4 生成失败与孤儿文件处理

若 HTML 写入、PDF 转换或数据库保存失败，`generate\_detection\_report`会删除本次新生成的 HTML 和 PDF 文件，避免失败产物残留。报告重新生成成功后，服务会清理旧报告文件。当前代码未实现独立的定时孤儿文件扫描机制；后台报告列表可以识别数据库记录存在但 PDF 文件缺失的`missing`状态，PDF 失败不影响原检测结果。

代码 5-8 报告生成失败清理路径

```
created_files = []

try:

    html_path.write_text(rendered_html, encoding="utf-8")

    created_files.append(html_path)

    pisa_status = pisa.CreatePDF(rendered_html, dest=pdf_file)

    if pisa_status.err:

        raise ReportServiceError("PDF 生成失败")

    created_files.append(pdf_path)

    report = save_generated_report(db, detection, html_path, pdf_path)

except Exception:

    for file_path in created_files:
```

```

        if file_path.exists():

            file_path.unlink()

        raise

```

5.11 前端主要功能实现

5.11.1 新闻检测与 URL 预览页面

前端检测页提供手工输入、示例填充、URL 提取、发布时间填写和联网搜索开关。URL 预览成功后，页面将标题、正文、来源和发布时间回填到同一表单，用户仍可编辑。提交检测时，前端将响应写入临时缓存并跳转结果页。

5.11.2 结果解释与证据展示页面

结果页按综合评分、证据质量、大模型判断和规则评分展示检测结论，并显示判断理由、风险点、关键词、有效证据、排除证据、相似新闻、处理步骤和免责声明。当`arbitration\_status`为`provider\_error`、`retry\_exhausted`或`unavailable`时，页面显示证据仲裁暂不可用提示，并支持登录用户重新评估。

5.11.3 历史记录与报告页面

历史页要求登录后访问，只展示当前用户记录。页面支持关键词和风险等级筛选，并展示报告状态；有报告的记录可以通过授权下载 PDF。ResultView 中也提供生成、重新生成和下载报告按钮，未登录用户会被引导登录。

5.11.4 管理员后台与数据可视化

管理员后台包含用户管理、检测记录、知识库、Prompt 模板、高风险新闻、统计、报告和系统日志页面。知识库页展示向量同步状态并提供重建入口；Prompt 页支持默认模板管理；高风险页支持复核和公开控制；日志页展示登录、检测、知识库、Prompt 和复核等关键操作。

表 5-6 前端页面、接口与主要状态

页面	主要接口	关键状态	实现说明
新闻检测	/detect/extract-preview、 /detect/news	extracting submitting enable_web_search	URL 回填 和手工检测入口
结果详情	/detect/{id} /report/generate/{id}	qualityState arbitrationUnavailable	评分、证 据、降级和报告

		reportBusy	
历史记录	/detect/history	筛选条件、report_url	仅本人记录 和报告下载
知识库后台	/admin/knowledge	vector_sync_status、 vector_sync_error	向量状态 与重建
高风险后台	/admin/high-risk	review_status、 is_public	复核和公 开控制
系统日志	/admin/logs	module、action、 keyword	关键操作 审计

图 5-7 至图 5-14 为本章运行验证阶段通过 Playwright 从真实前后端服务采集的系统页面截图，演示账号与演示数据均记录在《第五章撰写说明.md》中。



图 5-7 新闻检测页面与 URL 提取回填状态



图 5-8 检测结果总览、评分与报告按钮




图 5-9 有效证据与排除证据展示区域



图 5-10 联网候选证据与排除证据区域




图 5-11 历史记录与 PDF 报告状态



图 5-12 管理员知识库与向量同步状态



图 5-13 高风险记录复核列表




图 5-14 模型异常或仲裁不可用降级展示

5.12 异常处理、系统日志与运行保障

5.12.1 统一异常响应

后端在`main.py`注册 HTTP 异常、Pydantic 校验异常和 SQLAlchemy 异常处理器。接口层将业务异常转换为统一`code/message/data`响应，前端通过 Axios 拦截器统一处理 401 并清除本地登录态。

5.12.2 外部服务故障与降级处理

外部服务故障不会全部导致检测流程中断。URL 提取失败只影响预览；联网搜索失败会记录日志并使用本地证据继续；模型整体失败时系统进入规则评分降级；证据仲裁重试失败时，候选不参与证据质量和最终证据分支。Chroma 检索失败属于 RAG 基础能力不可用，检测接口返回 503。

表 5-5 系统异常与降级处理

故障位置	系统处理	用户提示	是否保存记录	日志状态
URL 提取失败	返回 422，不进入检测链路	链 接 提	否	接口日志

		取 失		
		败 或		
		安 全		
		拦截		
Embeddi	知识同步标记 failed 或检测	知	视	服务日志
ng 失败	检索失败	识 库 场 景		
		显 示 而定		
		错 误		
		或 检		
		测 503		
Chroma	检 测 抛 出	证 否		服务日志
不可用	KnowledgeRetrievalFailedError	据 检		
		索 失		
		败		
联 网 搜	捕获 BochaServiceError，使	通	是	warning 日志
索失败	用本地证据继续	常 不		
		阻 断		
		页面		
模 型 返	解析失败后默认字段或进入	结	是	服务日志
回异常	契约校验失败	果 显		
		示 降		
		级 或		
		重 试		
		提示		
聚 焦 重	arbitration_status=retry_exhau	证	是	analysis_paylo
试失败	sted	据 仲		ad 保存摘要
		裁 暂		
		不 可		
		用		

模型整体失败	模型调整失败 / 降级提示	最终分数使用规则分	模型是 risk_points 记录
数据库提交失败	服务器异常分回滚	事务回滚并返回 500	否 SQLAlchemy 异常处理
向量同步失败	后台显示向量错误	状态 failed，保留 MySQL 事实记录	是 vector_sync_error
PDF 生成失败	报告生成失败	删除本次文件，不影响检测记录	检测记录保留 服务异常

5.12.3 关键操作日志

系统日志覆盖注册、登录成功、登录失败、新闻检测、重新评估、知识库新增/修改/删除/向量化/重建、Prompt 模板操作、高风险复核和公开状态调整等。日志记录用户 ID、模块、动作、描述、IP 和时间，不记录密码、完整令牌、JWT 密钥、API 密钥或不必要的完整敏感正文。

5.12.4 配置管理与敏感信息保护

配置由`backend/.env`读取，包含数据库、JWT 密钥、DashScope、DeepSeek、Bocha、Chroma 路径、报告目录、限流和 CORS 等设置。`Settings`会拒绝缺失或占位的`SECRET\_KEY`，并将报告目录解析到后端源码目录之外。实际运行截图中未展示任何密钥、令牌或数据库密码。

5.13 本章小结

本章基于当前项目真实实现，说明了第 4 章提出的总体架构如何落到前后端模块、数据模型、服务调用和页面状态中。系统以 MySQL 为业务事实源，以 Chroma 作为派生语义索引，以 DeepSeek 模型完成证据约束下的结构化分析和仲裁，并通过分支式评分在正常、证据不足、模型失败和仲裁失败等状态下保持可解释输出。

运行验证表明，新闻输入、URL 预览、本地 RAG 检索、模型仲裁、评分、历史查询、PDF 报告、知识库向量状态和高风险复核等功能均已在当前系统中落地。对于尚未实现的独立孤儿文件扫描、EvidenceMatch 网络来源字段持久化等改进点，本章没有作为已完成功能写入正文，而是在撰写说明中单独列出。

参考文献

- [1] Shu K, Sliva A, Wang S, Tang J, Liu H. Fake News Detection on Social Media: A Data Mining Perspective[J]. ACM SIGKDD Explorations Newsletter, 2017, 19(1): 22-36.
- [2] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[C]. Advances in Neural Information Processing Systems, 2020.
- [3] Ji Z, Lee N, Frieske R, et al. Survey of Hallucination in Natural Language Generation[J]. ACM Computing Surveys, 2023, 55(12): 1-38.
- [4] Yang Y, Zhou Y, Ying Q, Qian Z, Zeng D, Liu L. Fact-checking based fake news detection: a review[EB/OL]. arXiv:2401.01717, 2024.
- [5] Quelle D, Bovet A. The perils and promises of fact-checking with large language models[J]. Frontiers in Artificial Intelligence, 2024, 7:1341697.
- [6] Li Y, He H, Bai J, Wen D. MCFEND: A Multi-source Benchmark Dataset for Chinese Fake News Detection[C]. Proceedings of the ACM Web Conference 2024, 2024: 4018-4027.
- [7] Ullrich H, Mlynář T, Drchal J. AIC CTU system at AVeriTeC: Re-framing automated fact-checking as a simple RAG task[EB/OL]. arXiv:2410.11446, 2024.
- [8] Yue Z, Zeng H, Shang L, Liu Y, Zhang Y, Wang D. Retrieval Augmented Fact Verification by Synthesizing Contrastive Arguments[EB/OL]. arXiv:2406.09815, 2024.
- [9] Ge Z, Wu Y, Chin D W K, Lee R K W, Cao R. Resolving Conflicting Evidence in Automated Fact-Checking: A Study on Retrieval-Augmented LLMs[EB/OL]. arXiv:2505.17762, 2025.
- [10] 张犬俊, 谢杨, 房春荣, 等. 检索增强生成在软件工程中的应用综述[J]. 软件学报, 2026, 37(3): 1316-1339. DOI:10.13328/j.cnki.jos.007567.
- [11] 高彦杰, 陈跃国. 大语言模型预训练系统关键技术综述[J]. 软件学报, 2026, 37(1): 200-229. DOI:10.13328/j.cnki.jos.007438.
- [12] 刘泽垣, 王鹏江, 宋晓斌, 等. 大语言模型的幻觉问题研究综述[J]. 软件学报, 2025, 36(3): 1152-1185. DOI:10.13328/j.cnki.jos.007242.